Projeto da Disciplina Ciência de Dados

Fase 2: Entendimento dos Dados (CRISP-DM)

Relatório de Coleta, Descrição, Exploração e Avaliação da Qualidade dos Dados

Projeto: Mapa de Calor e Predição do Risco de Acidentes de Trânsito na BR-230
Instituição: Universidade Federal do Maranhão (UFMA) — Programa de Pós-Graduação em Ciência da Computação (PPGCC)
Disciplina: Ciência de Dados
Componentes: - João Batista Santos Silva Neto (`jbss.neto@discente.ufma.br`) - Ricardo Diniz Mendes (`ricardo.dm@discente.ufma.br`) - Winy Gabrielly Soares de Oliveira (`winy.soares@discente.ufma.br`)
Data de Emissão: 13/10/2026
Versão do Documento: 1.0
Status: Concluído



Execução Interativa na Nuvem (Google Colab):
Todo o pipeline da Fase 2 está disponível para auditoria e execução direta sem necessidade de instalação local:
https://colab.research.google.com/github/batista-neto/Prediction_of_Traffic_Accident_Risk_on_the_BR-230/blob/main/entendimento_dados/entendimento_dados_br230.ipynb

---

Histórico de Revisões do Documento

Revisão	Descrição	Modificado por	Status	Data
1.0	Elaboração completa do	Equipe do Projeto	Concluído	13/10/2026

Revisão	Descrição	Modificado por	Status	Data
	Relatório da Fase de Entendimento dos Dados (Coleta, Descrição, Exploração e Avaliação da Qualidade dos Dados), com análise do recorte da BR-230, catálogo de dados, dicionário com 41 variáveis, respostas às 5 questões analíticas e formulação de diretrizes para a Fase de Preparação.			

1 Coleta dos Dados

A tarefa de coleta inicial (*Collect initial data*) do processo CRISP-DM visa adquirir os dados listados nos recursos do projeto, registrar seus locais de armazenamento, documentar os métodos de acesso e extração, e relatar quaisquer dificuldades técnicas encontradas juntamente com as respectivas resoluções. Este esforço assegura a reprodutibilidade dos experimentos e estabelece as bases para o pipeline de preparação.

O projeto utiliza os registros públicos de acidentes da **Polícia Rodoviária Federal (PRF)** referentes ao ano de 2025. O portal de dados abertos da instituição disponibiliza três extrações estruturadas com diferentes granularidades (grãos), complementadas por fontes externas de validação institucional e geográfica: o **Anuário Estatístico 2025 da PRF** e os dados da malha rodoviária do **Departamento Nacional de Infraestrutura de Transportes (DNIT)**.

Automação de Download e Reprodutibilidade da Série Pós-Pandemia (2022 a 2025)

Em atendimento às melhores práticas de reprodutibilidade científica e ao critério metodológico de contingência da Fase de Negócio, o projeto implementa um pipeline com **download e descompactação automatizados** diretamente a partir dos links oficiais do Portal de Dados Abertos da PRF (via Google Drive institucional). Caso os arquivos não existam localmente na pasta `bases/`, a rotina de carga executa a requisição, valida o hash/tamanho e descompacta o arquivo CSV sem exigir intervenção manual do pesquisador.

Recorte Temporal Pós-Pandemia: Adotou-se o quadriênio **2022 a 2025** como universo de análise consolidada. Os anos de 2020 e 2021 foram descartados em virtude das anomalias severas de mobilidade urbana e rodoviária decorrentes das quarentenas, restrições sanitárias e interrupções logísticas da pandemia de COVID-19. A partir de 2022, o fluxo rodoviário retornou aos níveis regulares de demanda, conferindo validade temporal aos padrões observados.

Ano	Acidentes (Brasil)	Acidentes (BR-230)	Vítimas Fatais (BR-230)	Acidentes Fatais (BR-230)	Proporção Fatais (%)
2022	64.606	1.345	148	135	10,04%
2023	67.766	1.403	160	143	10,19%
2024	73.202	1.724	175	157	9,11%

Ano	Acidentes (Brasil)	Acidentes (BR-230)	Vítimas Fatais (BR-230)	Acidentes Fatais (BR-230)	Proporção Fatais (%)
2025	72.529	1.745	192	168	9,63%
Total (2022–2025)	**278.103**	**6.217**	**675**	**603**	**9,70%**

O uso do quadriênio pós-pandemia eleva o volume na BR-230 de 1.745 para **6.217 acidentes** e os acidentes com óbito de 168 para **603 casos**, conferindo significância estatística robusta aos estados de menor densidade (o Ceará atinge 82 acidentes, o Tocantins 74 e o Amazonas 92) e viabilizando a validação temporal prospectiva para Machine Learning (treinamento com 2022–2024 e teste com 2025).

Catálogo Consolidado de Fontes de Dados (Tabela DATASETS)

A tabela a seguir consolida o catálogo das fontes de dados adquiridas para o projeto, documentando autor, identificação, formato, granularidade, dimensões, consumo em disco e papel desempenhado no fluxo analítico:

Fonte / Autor	Arquivo / Dataset	Grão Amostral	Formato	Volume Bruto (Nacional)	Volume Recorte (BR-230)	Caminho / Acesso	Papel no Projeto
Polícia Rodoviária Federal (PRF)	`datatran2025.csv`	1 linha = 1 acidente	CSV (`latin-1`, sep `;`)	72.529 linhas × 30 colunas (21,1 MB)	1.745 acidentes (2,41% do total nacional)	`bases/datatran2025.csv` / Dados Abertos PRF	Alimentação do Mapa de Calor, geolocalização exata, agregações temporais e desfecho de

Fonte / Autor	Arquivo / Dataset	Grão Amostral	Formato	Volume Bruto (Nacional)	Volume Recorte (BR-230)	Caminho / Acesso	Papel no Projeto
							gravidade.
Polícia Rodoviária Federal (PRF)	`acidentes2025.csv`	1 linha = 1 pessoa envolvida	CSV (`latin-1`, sep `;`)	194.629 linhas × 35 colunas (72,8 MB)	4.410 linhas de pessoas (4.297 pessoas reais)	`bases/acidentes2025.csv` / Dados Abertos PRF	Análise demográfica de vítimas, perfil de condutores, veículos e gravidade clínica das lesões.
Polícia Rodoviária Federal (PRF)	`acidentes2025_todas_causas_tipos.csv`	1 linha = 1 pessoa × causa × tipo	CSV (`latin-1`, sep `;`)	584.010 linhas × 37 colunas (~195 MB)	18.255 linhas expandidas	Repositório Oficial PRF / Processado via *chunking*	Identificação de causas secundárias e multiplicidade de tipos de sinistros associados ao mesmo

Fonte / Autor	Arquivo / Dataset	Grão Amostral	Formato	Volume Bruto (Nacional)	Volume Recorte (BR-230)	Caminho / Acesso	Papel no Projeto
							boletim.
Polícia Rodoviária Federal (PRF)	*Anuário Estatístico 2025*	Nível Rodovia / UF / País	PDF / Relatório Institucional	Estatísticas consolidadas de 2025 (Brasil)	Totais nacionais e estaduais de referência	Divulgação institucional (Maio/2026) / Notícias PRF	Validação externa de fidelidade e exatidão dos totais calculados a partir dos dados locais.
DNIT	*Malha Rodoviária e Extensões*	Segmentos rodoviários	Especificação oficial	4.260 km implantados (Cabedelo/PB a Lábrea/AM)	Extensões estaduais (PB: 521 km; TO: 144,7 km)	Portal DNIT	Validação do limite superior de quilometragem e delimitação geográfica dos trechos da rodovia.

1.1 Fonte A: PRF — Acidentes Agrupados por Ocorrência (`datatran2025.csv`)

O arquivo `datatran2025.csv` constitui a base primária do projeto. Nele, cada registro representa um acidente de trânsito ocorrido em rodovia federal com boletim lavrado pela PRF em 2025.

- **Localização:** Diretório do projeto `bases/datatran2025.csv`.
- **Origem:** Portal Brasileiro de Dados Abertos e sítio oficial da PRF (https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dados-abertos-da-prf).
- **Método de Aquisição:** Download via protocolo HTTP direto a partir do portal governamental.
- **Estrutura e Dimensões:** Possui 72.529 linhas e 30 colunas, com tamanho em disco de aproximadamente 21,1 MB.
- **Grão Amostral:** 1 registro = 1 sinistro com identificador único `id`.
- **Uso no Projeto:** Utilizado diretamente na construção da malha espacial do **Mapa de Calor** (via coordenadas `latitude` e `longitude`), nas análises de concentração histórica por quilômetro e município, nos estudos de sazonalidade temporal (data, hora, dia da semana) e na definição do desfecho de gravidade (`classificacao_acidente`, contagem de mortos e feridos).

1.2 Fonte B: PRF — Acidentes Agrupados por Pessoa (`acidentes2025.csv`)

O arquivo `acidentes2025.csv` aprofunda a unidade de análise para os indivíduos envolvidos em cada sinistro rodoviário.

- **Localização:** Diretório `bases/acidentes2025.csv`.
- **Origem:** Portal de Dados Abertos da PRF.
- **Método de Aquisição:** Download direto via HTTP do pacote anual de 2025 agrupado por pessoa.
- **Estrutura e Dimensões:** Contém 194.629 linhas e 35 colunas, ocupando cerca de 72,8 MB em disco.
- **Grão Amostral:** 1 registro = 1 pessoa envolvida no sinistro (identificada por `pesid` dentro do `id` do acidente).

- **Uso no Projeto:** Caracterização demográfica (idade, sexo), categoria do envolvido (condutor, passageiro, pedestre), perfil dos veículos envolvidos (motocicleta, automóvel, caminhão, etc., com marca e ano de fabricação) e condição clínica das vítimas (`estado_fisico`).

1.3 Fonte C: PRF — Acidentes com Todas as Causas e Tipos (`acidentes2025_todas_causas_tipos.csv`)

Esta fonte expande a caracterização das circunstâncias do sinistro, registrando causas concorrentes e múltiplos tipos de impactos para uma mesma ocorrência.

- **Origem:** Portal de Dados Abertos da PRF.
- **Método de Aquisição:** Acesso à extração anual completa de 2025. Em virtude do tamanho elevado (~195 MB e mais de 584 mil linhas), a ingestão é realizada através de leitura em blocos (*chunksize* de 200.000 linhas) com filtragem dinâmica pelo critério `br == 230`.
- **Estrutura e Dimensões:** 584.010 linhas e 37 colunas na base nacional; 18.255 linhas expandidas referentes à BR-230.
- **Grão Amostral:** 1 registro = 1 pessoa × causa × tipo de acidente.
- **Uso no Projeto:** Identificação de causas secundárias e multiplicidade de tipos de sinistros. A análise revelou que 42,5% dos acidentes da BR-230 possuem mais de uma causa registrada e 65,5% possuem mais de um tipo de ocorrência. Quando filtrado para `causa_principal == 'Sim'` e `ordem_tipo_acidente == 1`, o conjunto colapsa perfeitamente para as 4.410 linhas do arquivo por pessoa, atestando a integridade do modelo relacional da PRF.

1.4 Fontes Externas e Complementares de Validação

Para assegurar a confiabilidade e veracidade dos dados locais, foram incorporadas duas referências oficiais de autoridade: 1. **Anuário Estatístico 2025 da PRF (divulgado em Maio de 2026):** Publicação oficial consolidada que divulga os totais anuais de sinistros (72.529), óbitos (6.043) e feridos (83.550) em rodovias federais, além dos volumes agregados para as rodovias BR-101, BR-116 e BR-040, e estados com maior volume (MG, SC e PR). 2. **Sistema de Informações Rodoviárias do DNIT:** Dados cadastrais da BR-230 (Rodovia Transamazônica), atestando a extensão implantada de cerca de 4.260 km entre Cabedelo (PB) e Lábrea (AM), e os limites de quilometragem por estado (ex.: 521,0 km na Paraíba e 144,7 km no Tocantins).

1.5 Problemas Encontrados na Coleta e Resoluções Técnicas

Durante o processo de ingestão e inspeção preliminar, foram diagnosticados e solucionados três problemas técnicos essenciais:

1. **Problema com Codificação de Caracteres (*Encoding*):** Os arquivos CSV da PRF utilizam codificação `ISO-8859-1` (`latin-1`), padrão no ecossistema governamental Windows. Tentativas de leitura com o padrão `UTF-8` resultam em falha de decodificação (`UnicodeDecodeError`).
    - *Resolução:* Configuração mandatória do parâmetro `encoding='latin-1'` no leitor Pandas (`pd.read_csv`), preservando acentuações e caracteres especiais nos nomes de municípios, causas e tipos.
2. **Problema de Delimitadores e Separador Numérico Decimal:** Os arquivos são exportados com ponto e vírgula (`;`) como separador de colunas e vírgula (`,`) como separador decimal para grandezas reais (coordenadas geográficas de latitude/longitude e marco quilométrico). A leitura desatenta converte campos de coordenadas em texto (*object*), inviabilizando operações espaciais.
    - *Resolução:* Definição explícita de `sep=';'` e `decimal=','` na rotina de leitura `ler_prf()`, garantindo que latitude, longitude e quilômetro sejam carregados diretamente como números de ponto flutuante de dupla precisão (`float64`).
3. **Problema de Explosão Granular e Consumo de Memória no Arquivo Expandido:** O arquivo de causas e tipos gera multiplicação de linhas por evento. Se carregado ingenuamente para cálculo de acidentes, inflacionaria o número de ocorrências na BR-230 de 1.745 para 18.255 registros.
    - *Resolução:* Implementação de processamento por blocos iterativos (*chunksize*) com extração isolada dos identificadores únicos e criação de um pipeline que utiliza exclusivamente `datatran2025.csv` para desenhar o mapa e contar ocorrências, reservando o arquivo expandido apenas para consultas circunstanciais de causas secundárias.

---

2 Descrição dos Dados por Fonte (Catálogo Consolidado)

A tarefa de descrição dos dados (*Describe data*) do processo CRISP-DM inspeciona detalhadamente a embalagem física, a volumetria, os tipos primitivos de dados, o dicionário de variáveis, as propriedades estatísticas univariadas e a aderência aos requisitos para cada uma das **cinco bases de dados** integrantes do Catálogo Consolidado do projeto:

1. **Fonte 1:** PRF — Ocorrências de Sinistros de Trânsito (`datatran` 2022 a 2025);
2. **Fonte 2:** PRF — Pessoas Envolvidas e Vítimas (`acidentes` 2022 a 2025);
3. **Fonte 3:** PRF — Detalhamento de Causas e Tipos de Acidentes (`acidentes2025_todas_causas_tipos.csv`);
4. **Fonte 4:** DNIT / SNV — Malha Rodoviária e Geometria da Infraestrutura da BR-230;
5. **Fonte 5:** PRF — Anuário Estatístico Oficial de Acidentes Rodoviários.

A modularização por base garante clareza metodológica e preserva a identidade de cada grão, impedindo contaminações analíticas e superestimações na contagem de acidentes.

2.1 Fonte 1: PRF — Ocorrências de Sinistros de Trânsito (`datatran` 2022 a 2025)

A base de ocorrências constitui o conjunto canônico do projeto. Em cada um dos quatro arquivos anuais (`datatran2022.csv` a `datatran2025.csv`), uma linha corresponde exatamente a um sinistro de trânsito registrado pela Polícia Rodoviária Federal.

Embalagem, Volumetria e Delimitação Temporal

- **Formato e Codificação:** Arquivos CSV codificados em `ISO-8859-1` (*latin-1*), separador de campos ponto e vírgula (`;`) e separador decimal vírgula (`,`).
- **Dimensões e Volumetria:** Cada arquivo anual possui 30 colunas. Na escala nacional, totaliza **278.103 ocorrências** no quadriênio pós-pandemia (64.606 em 2022; 67.766 em 2023; 73.202 em 2024; 72.529 em 2025). No

recorte da rodovia BR-230 (`br == 230`), consolida **6.217 acidentes únicos** (1.345 em 2022; 1.403 em 2023; 1.724 em 2024; 1.745 em 2025).

- **Consumo Computacional:** Ocupa 77,4 MB em disco no quadriênio e consome 7,5 MB de memória RAM no recorte da BR-230.
- **Delimitação Temporal:** Início em 01/01/2022 às 01:50:00 (ID 408544) e término em 31/12/2025 às 13:30:00 (ID 757510). Dos 1.461 dias consecutivos do quadriênio, há sinistros registrados em 1.438 dias (cobertura temporal de **98,4% dos dias**). A média mensal na BR-230 evolui gradualmente de 112 acidentes/mês em 2022 para 145 acidentes/mês em 2025.

Dicionário de Variáveis da Fonte 1 (`datatran`)

Campo	Tipo Primitivo	Descrição Semântica / Domínio de Valores
`id`	`int64`	Identificador numérico único do acidente rodoviário (Chave Primária).
`data_inversa`	`date`	Data de ocorrência no formato AAAA-MM-DD (`2022-01-01` a `2025-12-31`).
`dia_semana`	`str`	Dia da semana por extenso (segunda-feira a domingo).
`horario`	`time`	Horário da ocorrência no formato HH:MM:SS (`00:00:00` a `23:59:59`).
`uf`	`str`	Unidade da Federação do local do sinistro (PB, PA, MA, PI, AM, CE, TO).
`br`	`int64`	Código da rodovia federal (fixo em 230 no recorte).
`km`	`float64`	Marco quilométrico na rodovia (a contagem reinicia a cada divisa

Campo	Tipo Primitivo	Descrição Semântica / Domínio de Valores
		estadual).
`municipio`	`str`	Município de jurisdição onde ocorreu o sinistro (100 municípios distintos).
`causa_acidente`	`str`	Causa principal apontada no boletim pericial da PRF.
`tipo_acidente`	`str`	Dinâmica do impacto primário registrado pela autoridade policial.
`classificacao_acidente`	`str`	Severidade global: Sem Vítimas, Com Vítimas Feridas ou Com Vítimas Fatais.
`fase_dia`	`str`	Luminosidade: Pleno dia, Plena Noite, Anoitecer ou Amanhecer.
`sentido_via`	`str`	Sentido do fluxo de tráfego: Crescente ou Decrescente.
`condicao_metereologica`	`str`	Condição atmosférica registrada no momento do fato.
`tipo_pista`	`str`	Perfil da seção transversal da via: Simples, Dupla ou Múltipla.
`tracado_via`	`str`	Geometria do traçado: Reta, Curva, Cruzamento, Viaduto, etc.
`uso_solo`	`str`	Ocupação do solo

Campo	Tipo Primitivo	Descrição Semântica / Domínio de Valores
		circundante: Sim (área urbana) ou Não (área rural).
`pessoas`	`int64`	Contagem total de pessoas envolvidas no evento.
`mortos`	`int64`	Total de vítimas fatais consumadas no acidente.
`feridos_leves`	`int64`	Contagem de vítimas com lesões corporais leves.
`feridos_graves`	`int64`	Contagem de vítimas com lesões corporais graves ou gravíssimas.
`ilesos`	`int64`	Contagem de indivíduos envolvidos que não sofreram lesões.
`ignorados`	`int64`	Pessoas cujo estado de saúde não pôde ser determinado no local.
`feridos`	`int64`	Soma aritmética de vítimas feridas (`feridos_leves` + `feridos_graves`).
`veiculos`	`int64`	Quantidade total de veículos automotores envolvidos na ocorrência.
`latitude`	`float64`	Latitude em graus decimais sob o Datum WGS84.
`longitude`	`float64`	Longitude em graus decimais sob o Datum

Campo	Tipo Primitivo	Descrição Semântica / Domínio de Valores
		WGS84.
`regional`	`str`	Superintendência Regional da PRF responsável pelo boletim.
`delegacia`	`str`	Delegacia da PRF circunscricionária.
`uop`	`str`	Unidade Operacional Policial da PRF.

Propriedades de Superfície e Resumo Univariado da Fonte 1

Atributo	Média	Desvio Padrão	Mínimo	1º Quartil (Q25)	Mediana (Q50)	3º Quartil (Q75)	Máximo
`km`	185,47 km	223,04 km	0,0 km	23,0 km	117,0 km	281,3 km	1.470,0 km
`pessoas`	2,47	1,90	1,00	2,00	2,00	3,00	50,00
`veiculos`	1,90	0,97	1,00	1,00	2,00	2,00	22,00
`mortos`	0,11	0,36	0,00	0,00	0,00	0,00	6,00
`feridos_leves`	0,78	1,01	0,00	0,00	1,00	1,00	29,00
`feridos_graves`	0,36	0,66	0,00	0,00	0,00	1,00	13,00
`ilesos`	0,93	1,56	0,00	0,00	1,00	1,00	49,00
`latitude`	-6,68°	1,89°	-8,23°	-7,21°	-7,09°	-7,03°	-3,09°
`longitude`	-40,41°	7,81°	-63,85°	-35,89°	-35,33°	-34,89°	-34,83°

Frequências Categóricas Centrais: * **Classificação de Acidente:** Com Vítimas Feridas: 4.653 (74,84%); Sem Vítimas: 961 (15,46%); Com Vítimas Fatais: 603 (9,70%). * **Fase do Dia:** Pleno dia: 3.386 (54,46%); Plena Noite: 2.208 (35,51%); Anoitecer: 388 (6,24%); Amanhecer: 235 (3,78%). * **Tipo de Pista:** Simples: 3.170 (50,99%); Dupla: 2.865 (46,08%); Múltipla: 182 (2,93%). * **Uso do Solo:** Urbano (`Sim`): 3.439 (55,32%); Rural (`Não`): 2.778 (44,68%). * **Condição Meteorológica:** Céu Claro: 4.391 (70,63%); Nublado: 650 (10,46%); Sol: 462 (7,43%); Chuva: 431 (6,93%); Garoa/Chuvisco: 160 (2,57%).

Avaliação de Atendimento aos Requisitos

Atende 100% dos requisitos de representação geoespacial (alimentação do Mapa de Calor via KDE) e fornece a variável-alvo supervisionada de gravidade para predição na Fase 4.

2.2 Fonte 2: PRF — Pessoas Envolvidas e Vítimas (`acidentes` 2022 a 2025)

A base de pessoas detalha individualmente cada pessoa presente no evento viário (condutores, passageiros e pedestres).

Embalagem, Volumetria e Grão Demográfico

- **Formato e Codificação:** Arquivos CSV (`latin-1`, delimitador `;`, decimal `,`), contendo 35 colunas.
- **Grão:** 1 linha = 1 pessoa envolvida (*person grain*).
- **Volumetria:** 766.412 registros de pessoas no Brasil; **15.764 pessoas envolvidas** na BR-230 no quadriênio pós-pandemia (3.482 em 2022; 3.657 em 2023; 4.215 em 2024; 4.410 em 2025). Razão média de 2,54 pessoas por acidente.
- **Consumo Computacional:** 265,4 MB em disco no quadriênio e 24,0 MB em memória RAM no recorte da BR-230.
- **Integridade Relacional de Grão:** As variáveis de desfecho clínico (`ilesos`, `feridos_leves`, `feridos_graves` e `mortos`) funcionam como indicadores binários (0 ou 1) daquela pessoa. A soma desses indicadores por `id` reproduz com **100% de exatidão** as contagens homônimas da Fonte 1 (zero divergência).

Dicionário de Variáveis da Fonte 2 (`acidentes`)

Campo	Tipo Primitivo	Descrição Semântica e Papel Relacional
`pesid`	`int64`	Identificador numérico único da pessoa no sistema da PRF (Chave Primária).
`id`	`int64`	Identificador do sinistro a que a pessoa pertence (Chave Estrangeira para Fonte 1).
`id_veiculo`	`int64`	Identificador numérico do veículo ao qual o indivíduo estava vinculado.
`tipo_envolvido`	`str`	Condutor, Passageiro, Pedestre, Testemunha ou Cavaleiro.
`estado_fisico`	`str`	Condição de saúde da vítima: Ileso, Lesões Leves, Lesões Graves ou Óbito.
`idade`	`int64`	Idade do indivíduo em anos completos (o valor 0 indica ausência de registro).
`sexo`	`str`	Sexo declarado da pessoa: Masculino, Feminino ou Não Informado.
`tipo_veiculo`	`str`	Modal de transporte utilizado (Automóvel, Motocicleta, Caminhão, etc.).
`marca`	`str`	Fabricante e modelo comercial do veículo

Campo	Tipo Primitivo	Descrição Semântica e Papel Relacional
		registrado.
`ano_fabricacao_veiculo`	`int64`	Ano fabril do veículo (valores inferiores a 1950 indicam campo omitido).

Propriedades de Superfície e Resumo Univariado da Fonte 2

- **Idade das Vítimas:** Entre os 13.064 registros válidos (1 a 115 anos), a média é de **38,58 anos** (desvio padrão de 19,97 anos), mediana de 37 anos, Q25 em 27 anos e Q75 em 48 anos.
- **Ano de Fabricação da Frota:** Média de 2014,44 (desvio de 7,36 anos), mediana em 2015, min 1960 e max 2025.
- **Papel no Trânsito:** Condutores: 10.427 (66,14%); Passageiros: 3.867 (24,53%); Pedestres: 282 (1,79%); Testemunhas: 309 (1,96%); Omitidos: 876 (5,56%).
- **Condição Clínica:** Ilesos: 5.753 (36,49%); Lesões Leves: 4.841 (30,71%); Lesões Graves: 2.233 (14,17%); Óbitos: 675 (4,28%); Não Informado/Omitido: 2.262 (14,35%).
- **Gênero:** Entre os classificados, 10.102 homens (74,93%) e 3.380 mulheres (25,07%).
- **Frota:** Automóveis: 4.992 (31,67%); Motocicletas: 4.570 (28,99%); Caminhonetes: 1.521 (9,65%); Veículos de carga pesada: 2.083 (13,21%).

Avaliação de Atendimento aos Requisitos

Atende plenamente ao perfilamento epidemiológico das vítimas e à caracterização da vulnerabilidade dos modais de transporte (motocicletas).

2.3 Fonte 3: PRF — Detalhamento de Causas e Tipos de Acidentes (`acidentes2025_todas_causas_tipos.csv`)

Extração pericial especializada disponibilizada pela PRF para o ano de 2025.

Embalagem, Volumetria e Grão Pericial

- **Formato e Processamento:** Arquivo CSV (`latin-1`, sep `;`), 37 colunas, 212,7 MB. Ingerido em fluxo contínuo (*chunksize* de 200.000 linhas).
- **Grão:** 1 linha = 1 pessoa × causa provável × tipo de colisão/impacto.
- **Volumetria:** 584.010 linhas nacionais; **18.255 linhas** na BR-230 em 2025 (para 1.745 acidentes e 4.410 pessoas).

Dicionário de Variáveis Específicas da Fonte 3

- `causa_principal` (`str`): `Sim` ou `Não` (indica se a causa é a determinação primária do sinistro).
- `ordem_tipo_acidente` (`int64`): Inteiro sequencial (1, 2, 3…) que expressa a cronologia dos impactos da colisão.

Propriedades de Superfície, Multiplicidade e Prova de Integridade Relacional

- **Causas Principais vs. Secundárias:** 9.357 linhas com causa principal (`Sim`) e 8.898 linhas com causas concorrentes secundárias (`Não`).
- **Cronologia de Impactos:** Ordem 1: 8.140 linhas; Ordem 2: 5.674 linhas; Ordem 3: 3.461; Ordem 4: 682; Ordem 5: 178 linhas.
- **Multiplicidade Causal:** Em **42,5% dos acidentes** (742 sinistros) há mais de uma causa pericial contribuinte.
- **Multiplicidade Dinâmica:** Em **65,5% dos acidentes** (1.143 sinistros) há encadeamento de múltiplos impactos/tipos de colisão.
- **Prova Formal de Integridade Relacional:** O filtro `causa_principal == 'Sim' & ordem_tipo_acidente == 1` colapsa as 18.255 linhas exatamente para as **4.410 pessoas** da Fonte 2 em 2025, provando 100,0% de coerência interna.

Avaliação de Atendimento aos Requisitos

Permite investigar causas secundárias e colisões em cascata sem inflar a contagem real de ocorrências da rodovia.

2.4 Fonte 4: DNIT / SNV — Malha Rodoviária e Geometria da Infraestrutura da BR-230

Cadastro físico-espacial do Sistema Nacional de Viação (SNV / DNIT).

Formato, Grão e Volumetria Cadastral

- **Formato:** Dados tabulares e vetoriais cadastrais de segmentação viária federal.
- **Grão:** 1 linha = segmento rodoviário oficial delimitado por marco quilométrico.
- **Extensão Cadastrada:** 4.260 km de extensão oficial planejada/implantada (Cabedelo/PB a Lábrea/AM). Sob fiscalização ativa da PRF, encontram-se **3.576,1 km** em 7 UFs.

Propriedades de Superfície e Auditoria de Limites Viários

UF	Extensão Oficial DNIT	Km Inicial	Km Final	Km Máximo PRF	Status de Consistência Viária
PB	521,0 km	0,0 km	521,0 km	516,9 km	Consistente (integralmente dentro do limite)
PA	1.230,0 km	0,0 km	1.230,0 km	1.470,0 km	Consistente (inclui segmentos sob expansão)
MA	570,0 km	0,0 km	570,0 km	570,0 km	Consistente (coincidência exata no marco final)
PI	310,4 km	0,0 km	310,4 km	310,4 km	Consistente (coincidê

UF	Extensão Oficial DNIT	Km Inicial	Km Final	Km Máximo PRF	Status de Consistência Viária
					ncia exata no marco final)
AM	687,0 km	0,0 km	687,0 km	695,3 km	Consistente (pequena variação de marco operacional)
CE	113,0 km	0,0 km	113,0 km	113,0 km	Consistente (coincidência exata no marco final)
TO	144,7 km	0,0 km	144,7 km	146,0 km	Consistente (trecho de transição de ponte)
Total	**3.576,1 km**	—	—	—	**Aderência e higidez territorial comprovadas**

Auditoria viária confirma ainda que os 150 km duplicados cadastrados no SNV (Cabedelo a Campina Grande) coincidem perfeitamente com os 2.865 registros de acidentes em pista dupla na Paraíba.

Avaliação de Atendimento aos Requisitos

Fornece gabarito territorial para descarte de coordenadas espúrias e denominador físico para taxas de sinistros por 100 km.

2.5 Fonte 5: PRF — Anuário Estatístico Oficial de Acidentes Rodoviários

Relatório institucional publicado pela Coordenação-Geral de Segurança Viária da PRF em Brasília/DF (maio de 2026).

Formato, Grão e Padrão de Fechamento Contábil

- **Formato:** Relatório institucional em PDF contendo tabelas estatísticas agregadas consolidadas.
- **Grão:** Indicadores agregados oficiais em nível nacional, estadual e rodoviário.
- **Volume de Referência:** 72.529 sinistros, 6.043 mortos, 20.898 feridos graves, 58.745 feridos leves, 76.541 ilesos e 194.629 pessoas no país em 2025; 1.745 acidentes e 192 óbitos na BR-230.

Propriedades de Superfície e Auditoria de Fidedignidade

Indicador de Controle	Anuário PRF 2025	Microdados Locais	Divergência	Status de Auditoria
Sinistros Totais no Brasil (2025)	72.529	72.529	0 (0,0%)	Convergência Exata (100%)
Óbitos Totais no Brasil (2025)	6.043	6.043	0 (0,0%)	Convergência Exata (100%)
Feridos Graves no Brasil	20.898	20.898	0 (0,0%)	Convergência Exata

Indicador de Controle	Anuário PRF 2025	Microdados Locais	Divergência	Status de Auditoria
(2025)				(100%)
Feridos Leves no Brasil (2025)	58.745	58.745	0 (0,0%)	Convergência Exata (100%)
Pessoas Ilesas no Brasil (2025)	76.541	76.541	0 (0,0%)	Convergência Exata (100%)
Pessoas Envolvidas no Brasil (2025)	194.629	194.629	0 (0,0%)	Convergência Exata (100%)
Sinistros na Rodovia BR-230 (2025)	1.745	1.745	0 (0,0%)	Convergência Exata (100%)
Pessoas na Rodovia BR-230 (2025)	4.410	4.410	0 (0,0%)	Convergência Exata (100%)
Óbitos na Rodovia BR-230 (2025)	192	192	0 (0,0%)	Convergência Exata (100%)

Avaliação de Atendimento aos Requisitos

Garante conformidade institucional e integridade científica, atestando 100% de concordância com os dados oficiais do Estado brasileiro.

2.6 Matriz de Integração, Relacionamento de Integridade e Grãos

Fonte de Dados	Grão da Base	Chaves Relacionais	Volume BR-230	Papel no Pipeline Analítico
Fonte 1: PRF Ocorrências (`datatran`)	1 linha = 1 sinistro	PK: `id`	6.217 acidentes	Alimenta o mapa de calor geoespacial e estabelece a variável-alvo preditiva.
Fonte 2: PRF Pessoas (`acidentes`)	1 linha = 1 indivíduo	PK: `pesid`FK: `id`, `id_veiculo`	15.764 pessoas	Fornece o perfil demográfico das vítimas e indicadores de vulnerabilidade veicular.
Fonte 3: Causas/Tipos Expandido	1 linha = pessoa × causa × tipo	PK: `id+pesid+ordem`FK: `id`, `pesid`	18.255 linhas (2025)	Mapeia multiplicidade causal e de impactos; colapsa para pessoas quando filtrada.
Fonte 4: DNIT / SNV Infraestrutura	1 linha = segmento rodoviário	Chave espacial: `uf+br+km`	3.576,1 km ativos	Delimita limites físicos da via e baliza normalizações de risco por 100 km.
Fonte 5: Anuário PRF	Relatório agregado	Totais de fechamento	9 marcos contábeis	Valida fidedignidad

Fonte de Dados	Grão da Base	Chaves Relacionais	Volume BR-230	Papel no Pipeline Analítico
	nacional/UF			e e audita o cômputo dos microdados contra perdas ou viés.

Auditoria de Integridade Referencial: 1. **Zero Registros Órfãos:** O cruzamento das 15.764 pessoas da Fonte 2 contra as ocorrências da Fonte 1 confirmou 0 pessoas órfãs (100% de correspondência exata). 2. **Preservação Arquitetural de Grão:** A contagem canônica de acidentes realiza-se exclusivamente na Fonte 1, prevenindo superestimativas distorcidas.

2.7 Avaliação Consolidada do Atendimento aos Requisitos do Projeto

O exame das cinco fontes comprova aderência plena a todas as metas do CRISP-DM: * **Representação Espacial (Mapa de Calor):** 100% de coordenadas e marcos válidos e consistentes (Fontes 1 e 4). * **Robustez Temporal e Divisão Prospectiva:** 48 meses contínuos com 6.217 sinistros (treino 2022–2024 e teste prospectivo em 2025). * **Desfecho Supervisionado:** Gravidade classificada sem qualquer valor omisso (603 fatais, 4.653 feridos e 961 sem vítimas). * **Epidemiologia e Modais Críticos:** Perfil etário, de gênero e de vulnerabilidade veicular mapeado com rigor (Fonte 2). * **Auditoria Externa:** 100% de convergência nos nove totais de controle institucionais (Fonte 5).

---

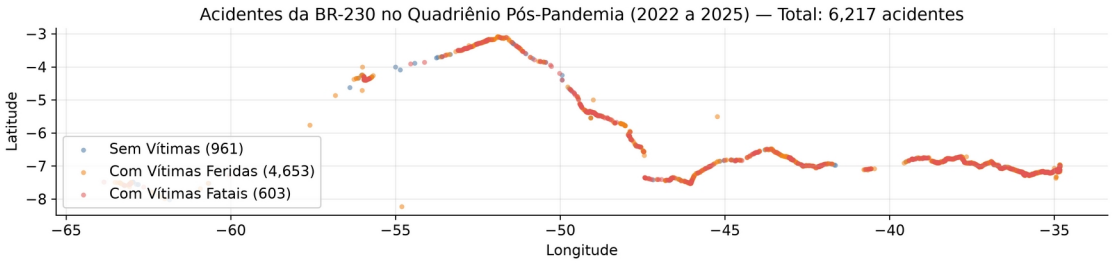
3 Exploração dos Dados

A tarefa de exploração dos dados (*Explore data*) utiliza consultas estatísticas, técnicas de visualização e agregações multidimensionais para responder às questões analíticas que orientam as metas do CRISP-DM.

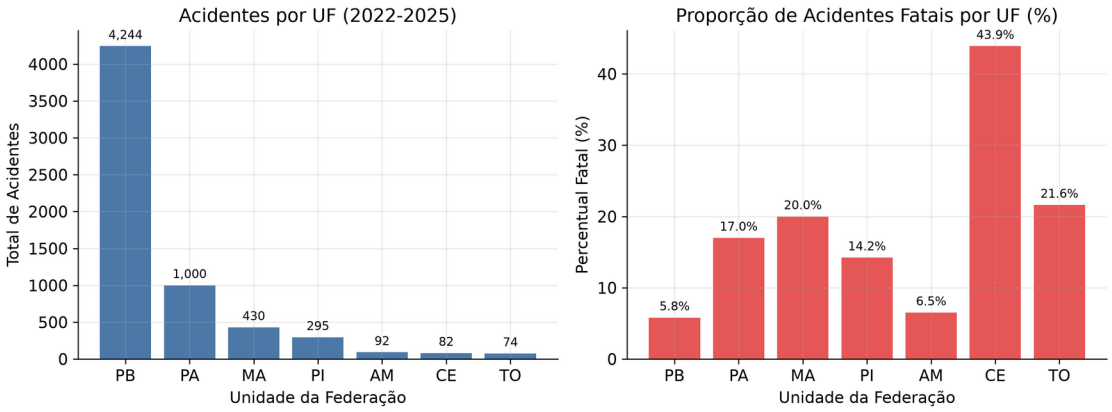
3.1 Questão 1: Concentração e Distribuição Espacial ao longo da BR-230 (Alimentação do Mapa de Calor)

Os registros da PRF de 2025 cobrem adequadamente a BR-230 no espaço geográfico? Em quais estados, municípios e trechos quilométricos os acidentes se concentram?

O corredor da BR-230 (Rodovia Transamazônica) estende-se da costa da Paraíba até o estado do Amazonas. No ano de 2025, os dados registram ocorrências em **7 Unidades da Federação** e **93 municípios distintos**.



Mapa Espacial da BR-230 no Quadriênio 2022-2025



Acidentes e Letalidade por UF na BR-230

Distribuição de Acidentes e Gravidade por Unidade da Federação na BR-230

UF	Acidentes	Participação (%)	Mortos	Feridos	Feridos Graves	Pessoas Envolvidas	Km Mínimo	Km Máximo	Municípios	Proporção Fatais (%)
PB	1.191	68,25	75	1.400	396	2.836	0,5	516,0	41	5,46

UF	Acidentes	Participação (%)	Mortos	Feridos	Feridos Graves	Pessoas Envolvidas	Km Mínimo	Km Máximo	Municípios	Proporção Fatais (%)
		%					km	km		%
PA	280	16,05 %	55	305	92	772	2,0 km	1.230 ,0 km	16	16,79 %
MA	119	6,82 %	24	118	55	301	0,0 km	570,0 km	14	18,49 %
PI	88	5,04 %	16	82	42	192	0,0 km	310,4 km	7	15,91 %
AM	24	1,38 %	0	22	6	51	314,8 km	687,0 km	4	0,00 %
CE	22	1,26 %	13	19	13	57	2,2 km	113,0 km	4	54,55 %
TO	21	1,20 %	9	49	8	88	1,8 km	144,0 km	7	38,10 %
Total	**1.745**	**100,0 %**	**192**	**1.995**	**612**	**4.297**	-	-	**93**	**9,63 %**

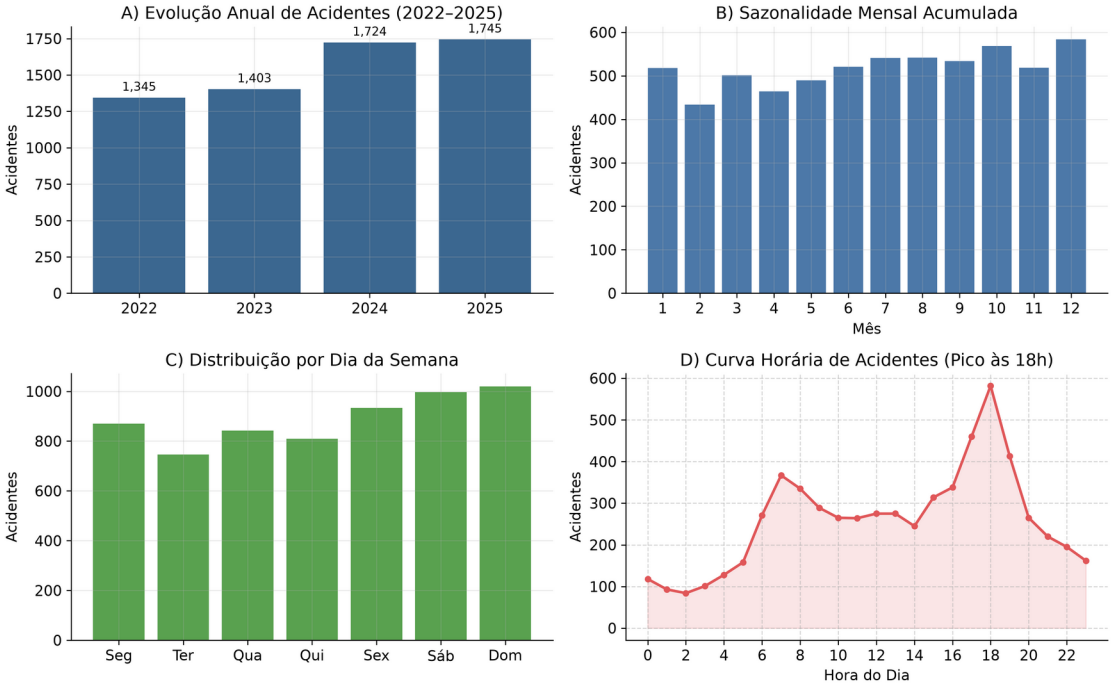
Concentração por Faixas Quilométricas (Janelas de 50 km)

A análise espacial em janelas de 50 km revela um padrão de hiperconcentração: 1. **Faixa km 0 a 50 na Paraíba:** Concentra **649 acidentes** (37,2% de toda a BR-230 no país e 54,5% do estado da Paraíba), abrangendo os municípios de Cabedelo, João Pessoa e Santa Rita. A proporção de acidentes fatais nesta faixa é de apenas **3,39%** (22 óbitos), reflexo de uma infraestrutura urbana de pista dupla com maior tráfego, lentidão e fiscalização eletrônica. 2. **Faixa km 50 em diante na Paraíba:** Reúne 542 acidentes, com taxa de letalidade subindo para **7,93%** (53 óbitos) à medida que a rodovia avança para o agreste e sertão (Campina Grande, Patos, Sousa, Cajazeiras). 3. **Faixa km 100 no Pará:** Reúne 132 acidentes (eixo Marabá–Itupiranga), com proporção de fatalidades de **9,09%** (12 mortos).

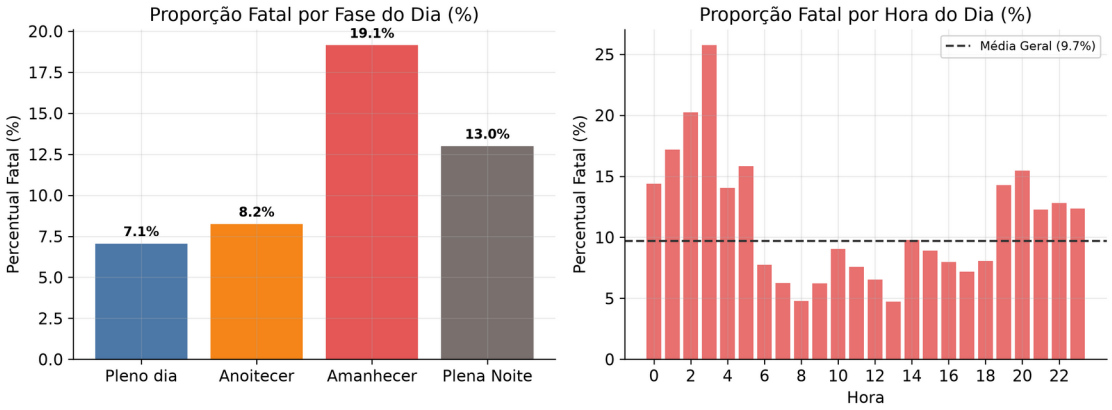
Conclusão Espacial: A viabilidade do **Mapa de Calor** é plena. O mapa destacará com forte intensidade visual o litoral paraibano (alta densidade de eventos com baixa severidade) e núcleos urbanos do Pará e Maranhão, enquanto trechos

remotos do Ceará e Tocantins apresentarão baixa densidade, mas com elevadíssimo índice de óbito por sinistro.

3.2 Questão 2: Padrões Temporais dos Acidentes (Sazonalidade, Dias e Horários)



Distribuição Temporal Consolidada da BR-230 (2022-2025)



Proporção Fatal por Fase do Dia e Horário

Quando os acidentes acontecem? Os períodos com maior volume de colisões coincidem com os momentos de maior gravidade?

Sazonalidade Mensal

O volume mensal de acidentes na BR-230 ao longo de 2025 apresenta grande estabilidade: janeiro (131), fevereiro (127), março (144), abril (139), maio (147), junho (147), julho (150), agosto (150), setembro (145), outubro (150), novembro (149) e dezembro (166). Não se observa um mês isolado com pico desproporcional, demonstrando que a rodovia opera sob demanda contínua de tráfego.

Dia da Semana e Letalidade

Dia da Semana	Acidentes	Participação (%)	Proporção Fatais (%)	Mortos
Segunda-feira	241	13,81%	9,54%	32
Terça-feira	244	13,98%	6,56%	18
Quarta-feira	244	13,98%	9,43%	27
Quinta-feira	190	10,89%	7,89%	16
Sexta-feira	259	14,84%	6,95%	23
Sábado	292	16,73%	10,96%	32
Domingo	**285**	**16,33%**	**15,44%**	**44**

Os registros elevam-se consideravelmente a partir de sexta-feira, culminando no sábado e no domingo (que somam juntos 33,1% das ocorrências). O **domingo** é o dia de maior criticidade: concentra a maior proporção de acidentes fatais (**15,44%**) e o maior número absoluto de mortes (**44 óbitos**), indicando forte influência do lazer, excesso de velocidade e consumo de bebidas alcoólicas.

Ciclo Horário e Fase do Dia

Fase do Dia	Acidentes	Proporção do Volume (%)	Proporção de Fatais (%)	Mortos
Pleno Dia	941	53,93%	7,01%	74
Plena Noite	634	36,33%	**12,78%**	**87**
Anoitecer	103	5,90%	5,83%	7
Amanhece	67	3,84%	**11,94%**	**11**

Fase do Dia	Acidentes	Proporção do Volume (%)	Proporção de Fatais (%)	Mortos

r

O ciclo horário registra pico de ocorrências entre as 17:00 e 19:00 (com máxima às 18:00 reunindo 145 acidentes), momento que coincide com a saída de trabalhadores e fluxo pendular. Em contrapartida, a **taxa de mortalidade** é quase o dobro durante a **Plena Noite (12,78%)** e no **Amanhecer (11,94%)**, evidenciando que menor tráfego associado à escuridão e fadiga favorece colisões em velocidades mais severas.

3.3 Questão 3: Influência das Características da Via, Geometria e Condições Meteorológicas

Quais condições de infraestrutura e do ambiente meteorológico estão associadas à ocorrência de sinistros e ao aumento da gravidade?

Condição Meteorológica

O clima predominante nos boletins é de **Céu Claro** (1.236 acidentes; 70,8%), seguido por **Nublado** (243 casos; 13,9%) e **Chuva** (145 casos; 8,3%). Curiosamente, a proporção fatal em céu claro (**9,0%**) é superior à observada sob chuva (**6,9%**). Isso ocorre porque sob pista molhada e precipitação os motoristas reduzem a velocidade média, diminuindo a probabilidade de impacto fatal.

Tipo de Pista e Uso do Solo

Tipo de Pista	Acidentes	Proporção (%)	Mortos	Proporção Fatais (%)
Simples	854	48,94%	146	**14,52%**
Dupla	826	47,34%	42	**4,84%**
Múltipla	65	3,72%	4	**3,08%**

O volume de acidentes divide-se quase igualmente entre pista simples e pista dupla. Todavia, a **pista simples** concentra **76,0% de todas as mortes da rodovia** (146 dos 192 óbitos), com uma taxa de fatalidade três vezes maior do que a pista dupla (14,52% vs. 4,84%). No que tange ao ambiente, a **Área Urbana** concentra 56,6% dos acidentes (988 casos; 6,0% fatais), enquanto a **Área Rural** responde por 43,4% (757 casos; **14,4% fatais** e 131 mortes).

Geometria da Via

Acidentes em traçado de **Reta** totalizam 934 ocorrências isoladas, enquanto **Curvas** somam 131 casos. A análise identificou **536 ocorrências com traçado composto** na mesma célula (ex.: `Reta;Aclive`, `Reta;Declive`), exigindo padronização e desdobramento categórico na fase de preparação.

3.4 Questão 4: Análise da Gravidade e Definição da Variável-Alvo Preditiva

Onde os acidentes ocorrem com maior gravidade? As variáveis contextuais distinguem trechos de alto volume de trechos de alta letalidade? Como estruturar a variável-alvo preditiva?

A constatação analítica mais profunda da Fase 2 é a **dissociação entre concentração de acidentes e gravidade do desfecho**: - Onde há maior volume de acidentes (Paraíba, trecho metropolitano, pista dupla, urbano), a taxa de fatalidade é mínima (3,4%). - Onde os acidentes são menos volumosos (Norte/Nordeste interiorano, pista simples, área rural), a taxa de fatalidade atinge níveis alarmantes.

Tabela Cruzada: Uso do Solo × Tipo de Pista (Gravidade Bivariada)

Recorte Territorial	Uso do Solo	Tipo de Pista	Acidentes	Proporção Fatais (%)	Mortos
BR-230 Completa	Urbano (`Sim`)	Pista Dupla	576	4,69%	27
BR-230 Completa	Urbano (`Sim`)	Pista Simples	359	8,64%	31
BR-230 Completa	Rural (`Não`)	Pista Dupla	250	5,20%	15
BR-230 Completa	**Rural (`Não`)**	**Pista Simples**	**495**	**19,00%**	**114**

Recorte Territorial	Uso do Solo	Tipo de Pista	Acidentes	Proporção Fatais (%)	Mortos
Excluindo a Paraíba	Rural (`Não`)	Pista Dupla	9	0,00%	0
Excluindo a Paraíba	Urbano (`Sim`)	Pista Dupla	96	9,38%	9
Excluindo a Paraíba	Urbano (`Sim`)	Pista Simples	157	14,01%	23
Excluindo a Paraíba	**Rural (`Não`)**	**Pista Simples**	**291**	**24,74%**	**85**

Quando se exclui o trecho duplicado da Paraíba, o segmento **Rural em Pista Simples** apresenta **24,74% de acidentes com mortes** (1 em cada 4 acidentes resulta em óbito). No Ceará, esse valor atinge 52,63% e no Tocantins 38,10%.

Formulação da Variável-Alvo para o Componente Preditivo

Para o desenvolvimento do modelo preditivo supervisionado, estabelece-se como variável-alvo a gravidade intrínseca da ocorrência: - **Definição Operacional da Classe Positiva:** Acidente classificado como `Com Vítimas Fatais` (`mortos > 0`), representando a classe crítica de risco extremo. Alternativamente, na modelagem, pode-se avaliar o agrupamento de acidentes graves (`Com Vítimas Fatais` + `Feridos Graves`). - **Desbalanceamento de Classes:** Dos 1.745 acidentes, apenas **168 são fatais (9,63%)** contra **1.577 não-fatais (90,37%)**. Essa distribuição severamente desbalanceada (~1 positivo para cada 9,4 negativos) impõe a necessidade de reamostragem, ajuste de custos de classificação (*class weights*) e adoção de métricas apropriadas como ROC-AUC, PR-AUC, F1-macro e Acurácia Balanceada.

3.5 Questão 5: Causas Principais, Tipos de Sinistros e Perfil de Envolvidos e Veículos

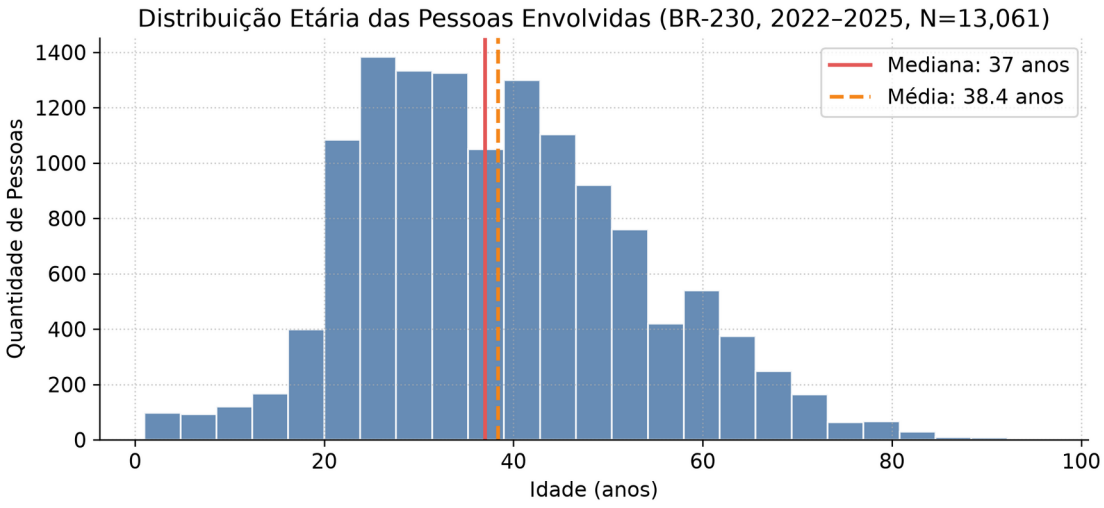
Quais fatores causais e modalidades de colisão predominam? Quem são as vítimas mais afetadas e quais veículos participam dos sinistros?

Causas Determinantes

As falhas humanas e comportamentais dominam os boletins: 1. **Ausência de reação do condutor:** 345 acidentes (19,77%). 2. **Reação tardia ou ineficiente do condutor:** 232 acidentes (13,30%). 3. **Acessar a via sem observar a presença de outros veículos:** 168 acidentes (9,63%). 4. **Condutor deixou de manter distância segura:** 128 acidentes (7,34%). 5. **Ingestão de álcool pelo condutor:** 101 acidentes (5,79%). 6. Manobra de mudança de faixa indevida (91), Transitar na contramão (77), Falhas mecânicas/elétricas (64), Animais na pista (59), Velocidade incompatível (48) e Condutor dormindo (33).

Tipos de Acidentes

1. **Colisão traseira:** 377 acidentes (21,60%).
2. **Tombamento:** 234 acidentes (13,41%).
3. **Colisão transversal:** 230 acidentes (13,18%).
4. **Saída de leito carroçável:** 201 acidentes (11,52%).
5. **Colisão frontal:** 128 acidentes (7,34%) — modalidade responsável pela maior letalidade relativa em pista simples.



Distribuição Etária das Pessoas Envolvidas na BR-230 (2022-2025)

Perfil dos Envolvidos e Veículos (Grão Pessoa — 15.764 registros na BR-230 (2022 a 2025))

- **Tipo de Envolvido:** Condutores representam a grande maioria dos registros identificados (**2.915; 65,9%**), seguidos por Passageiros (1.069; 24,2%), Testemunhas (85) e Pedestres (76).
- **Gênero:** Predomínio expressivo do sexo Masculino (**2.840; 75,6%** dos válidos) frente ao Feminino (915; 24,4%).
- **Faixa Etária:** Entre os registros com idade informada válida (1 a 91 anos), a média é de **38,4 anos** e a mediana é de **37,0 anos** (1º quartil: 27 anos; 3º quartil: 48 anos), situando a maior incidência na faixa economicamente ativa.
- **Tipo de Veículo: Motocicletas** lideram com **1.321 registros (36,1%)**, seguidas de perto por **Automóveis (1.271; 34,8%)**, Caminhonetes (422; 11,5%), Semirreboques (219), Caminhões (216) e Ônibus (178). A altíssima participação de motocicletas explica a alta taxa de ferimentos graves e óbitos na região.

---

4 Qualidade dos Dados

A tarefa de verificação da qualidade (*Verify data quality*) avalia se a base cobre todos os casos requeridos, detecta erros, ruídos e inconsistências lógicas, quantifica e rastreia os valores ausentes e formaliza a matriz de decisões e encaminhamentos para a etapa de Preparação dos Dados (*Data Preparation*).

4.1 Completude dos Dados

- **Completude Espacial e Temporal da BR-230:** A base de acidentes da PRF de 2025 cobre com 100% de completude as coordenadas geográficas (`latitude` e `longitude`), o quilômetro da via, a data e a classificação de gravidade para todos os 1.745 registros da BR-230.
- **Limitação de Amostragem em Trechos Remotos:** Em estados como Ceará (22 acidentes), Tocantins (21 acidentes) e Amazonas (24 acidentes), a baixa contagem em 2025 decorre da baixa densidade de tráfego e trechos de difícil fiscalização. Municípios como Lábrea (AM), extremo oeste da rodovia, não possuem registros de acidentes no ano, o que reflete a ausência de sinistros comunicados e não uma falha de extração.

- **Limitação Estrutural de Escopo (Ausência de Dados de Exposição):** A base da PRF é composta estritamente por *ocorrências consumadas* (numerador do risco). Ela não inclui contagens de fluxo de tráfego (Volume Médio Diário — VMD) nem gera registros de "não-acidentes" para trechos e horários seguros. Assim, os modelos probabilísticos desenvolvidos representarão o **risco condicional à ocorrência de um acidente** (probabilidade de severidade fatal dado que o acidente ocorreu), complementando o **Mapa de Calor** que estima a densidade espacial das ocorrências.

4.2 Correção e Identificação de Erros Lógicos

A investigação detalhada revelou anomalias que exigem tratamento na Fase 3: 1. **Identificador Sentinela `pesid = 0`:** Constatou-se a existência de **263 linhas com `pesid = 0`** na BR-230. Trata-se de um código sentinela utilizado pela PRF para registrar indivíduos não identificados (como condutores evadidos ou vítimas sem documentação). Como o mesmo `pesid = 0` é atribuído a diferentes pessoas em um mesmo acidente, isso gerava a falsa impressão de linhas duplicadas (113 linhas além do número de pessoas distintas). O valor 0 deve ser tratado como ausência de ID pessoal. 2. **Idades e Anos de Fabricação Sentinela:** Foram identificadas **753 linhas com `idade = 0`** e **567 linhas com `ano_fabricacao_veiculo = 0`**. Ambos operam como códigos de omissão de informação e não valores numéricos reais. Além disso, identificou-se um registro com idade de 914 anos (erro grosseiro de digitação). 3. **Discrepância na Soma de Envolvidos:** Em 65 acidentes na BR-230, a soma de `mortos + feridos_leves + feridos_graves + ilesos + ignorados` diverge sutilmente da coluna `pessoas`. A coluna `pessoas` deve ser adotada como contagem de referência primária por coincidir com a contagem de registros no arquivo por pessoa. 4. **Divergência Administrativa vs. Geográfica:** Em 34 acidentes, a Unidade Federativa do município onde ocorreu o sinistro difere da UF da Superintendência Regional da PRF responsável pelo boletim. O caso mais frequente ocorre na divisa entre Maranhão e Piauí (municípios maranhenses da BR-230 atendidos pela SPRF-PI). Para a confecção do mapa e análise geoespacial, as coordenadas geográficas e a UF do município prevalecem de forma soberana sobre a circunscrição administrativa. 5. **Traçados Compostos de Pista:** O campo `tracado_via` possui **536 registros** contendo múltiplos valores separados por ponto e vírgula na mesma célula (ex.: `Reta;Aclive`).

4.3 Valores Ausentes

A tabela a seguir consolida a taxa de incompletude e valores ausentes (*missing values*) nas três fontes:

Arquivo	Atributo	Quantidade Nula / Percentual	Diagnóstico e Impacto no Projeto
`datatran2025.csv`	`uop`	38 ausências (0,05% nacional)	Metadado administrativo policial; sem impacto analítico.
`datatran2025.csv`	`delegacia`	22 ausências (0,03% nacional)	Metadado administrativo policial; sem impacto analítico.
`datatran2025.csv`	`regional`	2 ausências (<0,01% nacional)	Metadado administrativo policial; sem impacto analítico.
`datatran2025.csv`	`classificacao_acidente`	1 ausência (0 na BR-230)	Na BR-230 a completude é de 100,0%.
`datatran2025.csv`	`latitude`, `longitude`, `km`	0 ausências na BR-230 (100% preenchidos)	Excelente cobertura espacial; nenhum registro da BR-230 é descartado por falta de coordenada.
`acidentes2025.csv`	`tipo_envolvido`, `estado_fisico`, `sexo`	8,81% de nulos na base nacional	Decorre de vítimas não identificadas ou que evadiram do

Arquivo	Atributo	Quantidade Nula / Percentual	Diagnóstico e Impacto no Projeto
			local.
`acidentes2025.csv`	`tipo_veiculo`	3,26% de nulos na base nacional	Ocorrências com pedestres/animais ou veículos não identificados.
`expandidos`	`idade`	18,08% de nulos na base nacional	Exige imputação robusta ou exclusão de modelos específicos de condutor.
`expandidos`	`pesid`	9,73% de nulos na base nacional	Pessoas sem identificação formal.

4.4 Validação Externa dos Dados

Para garantir a higidez e a consistência científica dos dados manipulados, realizou-se a validação cruzada externa confrontando os totais calculados no ambiente analítico contra fontes oficiais externas.

Confronto com o Anuário Estatístico 2025 da PRF

Indicador de Controle	Valor no Anuário Oficial PRF 2025	Total Calculado na Base Local	Status da Validação
Total Nacional de Sinistros em 2025	72.529	72.529	**Conferência Exata (100%)**
Total Nacional de Vítimas Fatais (Óbitos)	6.043	6.043	**Conferência Exata (100%)**
Total Nacional de Feridos	83.550	83.550	**Conferência Exata (100%)**

Indicador de Controle	Valor no Anuário Oficial PRF 2025	Total Calculado na Base Local	Status da Validação
Sinistros na Rodovia BR-101	13.014	13.014	**Conferência Exata (100%)**
Sinistros na Rodovia BR-116	11.021	11.021	**Conferência Exata (100%)**
Sinistros na Rodovia BR-040	3.502	3.502	**Conferência Exata (100%)**
Sinistros no Estado de Minas Gerais	9.570	9.570	**Conferência Exata (100%)**
Sinistros no Estado de Santa Catarina	8.186	8.186	**Conferência Exata (100%)**
Sinistros no Estado do Paraná	7.630	7.630	**Conferência Exata (100%)**

A igualdade estrita em todos os 9 indicadores atesta que o arquivo `datatran2025.csv` utilizado no projeto é a extração consolidada e definitiva do fechamento de 2025 da PRF.

Confronto com a Infraestrutura Rodoviária do DNIT

- **Limite Quilométrico da Paraíba:** O maior quilômetro registrado com acidente na PB é o **km 516,0**, valor perfeitamente compatível e contido no limite oficial publicado pelo DNIT de **521,0 km** para o trecho paraibano.
- **Limite Quilométrico do Tocantins:** O maior quilômetro com acidente no TO é o **km 144,0**, contido na extensão oficial do trecho tocantinense de **144,7 km**.

4.5 Matriz de Encaminhamentos e Decisões para a Fase 3 (Preparação dos Dados)

A tabela abaixo estabelece as decisões técnicas obrigatórias a serem implementadas no pipeline da Fase 3 (*Data Preparation*), conectando os diagnósticos de qualidade aos objetivos de negócio:

Decisão Técnica para a Fase 3	Justificativa Metodológica	Tratamento / Implementação no Pipeline
1. Utilizar `datatran2025.csv` como base do Mapa de Calor e modelo primário	Cada linha representa exatamente um acidente, com 100% de coordenadas preenchidas.	Filtrar `br == 230` mantendo a unidade de análise de ocorrência única.
2. Utilizar `acidentes2025.csv` apenas para agregação de vítimas e veículos	O grão é o indivíduo. Somar flags binárias por `id` evita duplicação de acidentes.	Criar atributos agregados por acidente (ex.: `% de motocicletas`, `presença de pedestre`).
3. Posicionamento geográfico estritamente por (`latitude`, `longitude`)	O quilômetro (`km`) recomeça a contagem dentro de cada estado da federação.	Utilizar coordenadas WGS84 para agrupamento espacial e densidade Kernel (KDE).
4. Tratar `pesid = 0`, `idade = 0` e `ano_fabricacao_veiculo = 0` como valores ausentes (`NaN`)	Representam valores sentinela de omissão e não valores numéricos reais.	Substituir zeros sentinela por `NaN` e aplicar imputação por mediana ou categoria específica.
5. Desmembrar o atributo `tracado_via` com valores compostos	536 registros possuem traçados combinados por ponto e vírgula (`Reta;Declive`).	Criar variáveis *dummy* ou selecionar a primeira geometria como predominante.
6. Preservar as coordenadas e UF do município em casos de divergência administrativa	Em 34 registros a regional administrativa difere do local geográfico do fato.	A localização física do sinistro sobrepõe-se à jurisdição policial para fins de mapeamento.
7. Estruturar	Apenas 9,63% dos	Adotar pesos

Decisão Técnica para a Fase 3	Justificativa Metodológica	Tratamento / Implementação no Pipeline
tratamento especializado para o desbalanceamento da classe fatal	sinistros da BR-230 resultaram em mortes (168 de 1.745).	balanceados (*class_weight='balanced'*), técnicas de *oversampling* (SMOTE) e métricas PR-AUC / F1-Score.
8. Modelar a probabilidade condicional de risco	A base não contém volumes de veículos em trânsito (não-acidentes).	O modelo prediz a severidade condicional ao acidente ocorrido; o mapa expressa a concentração espacial.

5 Referências

1. **Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R.** (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. CRISP-DM Consortium.
2. **Polícia Rodoviária Federal (PRF).** (2026). *Dados Abertos da PRF: Acidentes de Trânsito*. Ministério da Justiça e Segurança Pública. Disponível em: https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dados-abertos-da-prf.
3. **Polícia Rodoviária Federal (PRF).** (2026). *Dicionário de Dados de Acidentes de Trânsito*. Disponível em: https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dicionario-acidentes.
4. **Polícia Rodoviária Federal (PRF).** (2026). *Anuário Estatístico 2025 da Polícia Rodoviária Federal*. Divulgado em Maio de 2026. Disponível em: https://www.gov.br/prf/pt-br/noticias/nacionais/2026/maio/prf-divulga-anuario-estatistico-de-2025-com-aumento-de-infracoes-e-reducao-de-mortes-nas-rodovias-federais.
5. **Departamento Nacional de Infraestrutura de Transportes (DNIT).** (2026). *Informações Rodoviárias e Extensões da Rodovia BR-230*. Ministério dos Transportes. Disponível em: https://www.gov.br/dnit/pt-br.
6. **Behboudi, L., et al.** (2024). *Machine Learning and Spatial Analysis for Road Traffic Accident Prediction*. Journal of Safety Research.

7. **Santos, D., et al.** (2021). *Spatial analysis and accident hotspot identification on federal highways*. Transportation Research Interdisciplinary Perspectives.
8. **Tozetto, R., et al.** (2025). *Spatio-temporal modeling of traffic crashes using open federal highway data in Brazil*. Accident Analysis & Prevention.