Projeto da Disciplina Ciência de Dados

Fase 2: Entendimento dos Dados (CRISP-DM)

Relatório de Coleta, Descrição, Exploração e Avaliação da Qualidade dos Dados

Projeto: Mapa de Calor e Predição do Risco de Acidentes de Trânsito na BR-230
Instituição: Universidade Federal do Maranhão (UFMA) — Programa de Pós-Graduação em Ciência da Computação (PPGCC)
Disciplina: Ciência de Dados
Componentes: - João Batista Santos Silva Neto (`jbss.neto@discente.ufma.br`) - Ricardo Diniz Mendes (`ricardo.dm@discente.ufma.br`) - Winy Gabrielly Soares de Oliveira (`winy.soares@discente.ufma.br`)
Data de Emissão: 13/10/2026
Versão do Documento: 1.0
Status: Concluído

Histórico de Revisões do Documento

Revisão	Descrição	Modificado por	Status	Data
1.0	Elaboração completa do Relatório da Fase de Entendimento dos Dados (Coleta, Descrição, Exploração e Avaliação da Qualidade dos Dados),	Equipe do Projeto	Concluído	13/10/2026

Revisão	Descrição	Modificado por	Status	Data
	com análise do recorte da BR-230, catálogo de dados, dicionário com 41 variáveis, respostas às 5 questões analíticas e formulação de diretrizes para a Fase de Preparação.			

1 Coleta dos Dados

A tarefa de coleta inicial (*Collect initial data*) do processo CRISP-DM visa adquirir os dados listados nos recursos do projeto, registrar seus locais de armazenamento, documentar os métodos de acesso e extração, e relatar quaisquer dificuldades técnicas encontradas juntamente com as respectivas resoluções. Este esforço assegura a reprodutibilidade dos experimentos e estabelece as bases para o pipeline de preparação.

O projeto utiliza os registros públicos de acidentes da **Polícia Rodoviária Federal (PRF)** referentes ao ano de 2025. O portal de dados abertos da instituição disponibiliza três extrações estruturadas com diferentes granularidades (grãos), complementadas por fontes externas de validação institucional e geográfica: o **Anuário Estatístico 2025 da PRF** e os dados da malha rodoviária do **Departamento Nacional de Infraestrutura de Transportes (DNIT)**.

Automação de Download e Reprodutibilidade da Série Pós-Pandemia (2022 a 2025)

Em atendimento às melhores práticas de reprodutibilidade científica e ao critério metodológico de contingência da Fase de Negócio, o projeto implementa um pipeline com **download e descompactação automatizados** diretamente a partir dos links oficiais do Portal de Dados Abertos da PRF (via Google Drive institucional). Caso os arquivos não existam localmente na pasta `bases/`, a rotina de carga executa a requisição, valida o hash/tamanho e descompacta o arquivo CSV sem exigir intervenção manual do pesquisador.

Recorte Temporal Pós-Pandemia: Adotou-se o quadriênio **2022 a 2025** como universo de análise consolidada. Os anos de 2020 e 2021 foram descartados em virtude das anomalias severas de mobilidade urbana e rodoviária decorrentes das quarentenas, restrições sanitárias e interrupções logísticas da pandemia de COVID-19. A partir de 2022, o fluxo rodoviário retornou aos níveis regulares de demanda, conferindo validade temporal aos padrões observados.

Ano	Acidentes (Brasil)	Acidentes (BR-230)	Vítimas Fatais (BR-230)	Acidentes Fatais (BR-230)	Proporção Fatais (%)
2022	64.606	1.345	148	135	10,04%
2023	67.766	1.403	160	143	10,19%
2024	73.202	1.724	175	157	9,11%
2025	72.529	1.745	192	168	9,63%
Total (2022–2025)	**278.103**	**6.217**	**675**	**603**	**9,70%**

O uso do quadriênio pós-pandemia eleva o volume na BR-230 de 1.745 para **6.217 acidentes** e os acidentes com óbito de 168 para **603 casos**, conferindo significância estatística robusta aos estados de menor densidade (o Ceará atinge 82 acidentes, o Tocantins 74 e o Amazonas 92) e viabilizando a validação temporal prospectiva para Machine Learning (treinamento com 2022–2024 e teste com 2025).

Catálogo Consolidado de Fontes de Dados (Tabela DATASETS)

A tabela a seguir consolida o catálogo das fontes de dados adquiridas para o projeto, documentando autor, identificação, formato, granularidade, dimensões, consumo em disco e papel desempenhado no fluxo analítico:

Fonte / Autor	Arquivo / Dataset	Grão Amostral	Formato	Volume Bruto (Nacional)	Volume Recorte (BR-230)	Caminho / Acesso	Papel no Projeto
Polícia Rodoviária Federal (PRF)	`datatran2025.csv`	1 linha = 1 acidente	CSV (`latin-1`, sep `;`)	72.529 linhas × 30 colunas (21,1 MB)	1.745 acidentes (2,41% do total nacional)	`bases/datatran2025.csv` / Dados Abertos PRF	Alimentação do Mapa de Calor, geolocalização exata, agregações temporais e desfecho de gravidade.
Polícia Rodoviária Federal (PRF)	`acidentes2025.csv`	1 linha = 1 pessoa envolvida	CSV (`latin-1`, sep `;`)	194.629 linhas × 35 colunas (72,8 MB)	4.410 linhas de pessoas (4.297 pessoas reais)	`bases/acidentes2025.csv` / Dados Abertos PRF	Análise demográfica de vítimas, perfil de condutores, veículos e gravidade clínica das lesões.

Fonte / Autor	Arquivo / Dataset	Grão Amostral	Formato	Volume Bruto (Nacional)	Volume Recorte (BR-230)	Caminho / Acesso	Papel no Projeto
Polícia Rodoviária Federal (PRF)	`acidentes2025_todas_causas_tipos.csv`	1 linha = 1 pessoa × causa × tipo	CSV (`latin-1`, sep `;`)	584.010 linhas × 37 colunas (~195 MB)	18.255 linhas expandidas	Repositório Oficial PRF / Processado via *chunking*	Identificação de causas secundárias e multiplicidade de tipos de sinistros associados ao mesmo boletim.
Polícia Rodoviária Federal (PRF)	*Anuário Estatístico 2025*	Nível Rodovia / UF / País	PDF / Relatório Institucional	Estatísticas consolidadas de 2025 (Brasil)	Totais nacionais e estaduais de referência	Divulgação institucional (Maio/2026) / Notícias PRF	Validação externa de fidelidade e exatidão dos totais calculados a partir dos dados locais.
DNIT	*Malha*	Segme	Especific	4.260 km	Extensõe	Portal	Validaç

Fonte / Autor	Arquivo / Dataset	Grão Amostral	Formato	Volume Bruto (Nacional)	Volume Recorte (BR-230)	Caminho / Acesso	Papel no Projeto
	Rodoviária e Extensões	ntos rodoviários	ação oficial	implantados (Cabedelo/PB a Lábrea/AM)	s estaduais (PB: 521 km; TO: 144,7 km)	DNIT	ão do limite superior de quilometragem e delimitação geográfica dos trechos da rodovia.

1.1 Fonte A: PRF — Acidentes Agrupados por Ocorrência (`datatran2025.csv`)

O arquivo `datatran2025.csv` constitui a base primária do projeto. Nele, cada registro representa um acidente de trânsito ocorrido em rodovia federal com boletim lavrado pela PRF em 2025.

- **Localização:** Diretório do projeto `bases/datatran2025.csv`.
- **Origem:** Portal Brasileiro de Dados Abertos e sítio oficial da PRF (https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dados-abertos-da-prf).
- **Método de Aquisição:** Download via protocolo HTTP direto a partir do portal governamental.
- **Estrutura e Dimensões:** Possui 72.529 linhas e 30 colunas, com tamanho em disco de aproximadamente 21,1 MB.
- **Grão Amostral:** 1 registro = 1 sinistro com identificador único `id`.

- **Uso no Projeto:** Utilizado diretamente na construção da malha espacial do **Mapa de Calor** (via coordenadas `latitude` e `longitude`), nas análises de concentração histórica por quilômetro e município, nos estudos de sazonalidade temporal (data, hora, dia da semana) e na definição do desfecho de gravidade (`classificacao_acidente`, contagem de mortos e feridos).

1.2 Fonte B: PRF — Acidentes Agrupados por Pessoa (`acidentes2025.csv`)

O arquivo `acidentes2025.csv` aprofunda a unidade de análise para os indivíduos envolvidos em cada sinistro rodoviário.

- **Localização:** Diretório `bases/acidentes2025.csv`.
- **Origem:** Portal de Dados Abertos da PRF.
- **Método de Aquisição:** Download direto via HTTP do pacote anual de 2025 agrupado por pessoa.
- **Estrutura e Dimensões:** Contém 194.629 linhas e 35 colunas, ocupando cerca de 72,8 MB em disco.
- **Grão Amostral:** 1 registro = 1 pessoa envolvida no sinistro (identificada por `pesid` dentro do `id` do acidente).
- **Uso no Projeto:** Caracterização demográfica (idade, sexo), categoria do envolvido (condutor, passageiro, pedestre), perfil dos veículos envolvidos (motocicleta, automóvel, caminhão, etc., com marca e ano de fabricação) e condição clínica das vítimas (`estado_fisico`).

1.3 Fonte C: PRF — Acidentes com Todas as Causas e Tipos (`acidentes2025_todas_causas_tipos.csv`)

Esta fonte expande a caracterização das circunstâncias do sinistro, registrando causas concorrentes e múltiplos tipos de impactos para uma mesma ocorrência.

- **Origem:** Portal de Dados Abertos da PRF.
- **Método de Aquisição:** Acesso à extração anual completa de 2025. Em virtude do tamanho elevado (~195 MB e mais de 584 mil linhas), a ingestão é realizada através de leitura em blocos (*chunksize* de 200.000 linhas) com filtragem dinâmica pelo critério `br == 230`.
- **Estrutura e Dimensões:** 584.010 linhas e 37 colunas na base nacional; 18.255 linhas expandidas referentes à BR-230.
- **Grão Amostral:** 1 registro = 1 pessoa × causa × tipo de acidente.

- **Uso no Projeto:** Identificação de causas secundárias e multiplicidade de tipos de sinistros. A análise revelou que 42,5% dos acidentes da BR-230 possuem mais de uma causa registrada e 65,5% possuem mais de um tipo de ocorrência. Quando filtrado para `causa_principal == 'Sim'` e `ordem_tipo_acidente == 1`, o conjunto colapsa perfeitamente para as 4.410 linhas do arquivo por pessoa, atestando a integridade do modelo relacional da PRF.

1.4 Fontes Externas e Complementares de Validação

Para assegurar a confiabilidade e veracidade dos dados locais, foram incorporadas duas referências oficiais de autoridade: 1. **Anuário Estatístico 2025 da PRF (divulgado em Maio de 2026):** Publicação oficial consolidada que divulga os totais anuais de sinistros (72.529), óbitos (6.043) e feridos (83.550) em rodovias federais, além dos volumes agregados para as rodovias BR-101, BR-116 e BR-040, e estados com maior volume (MG, SC e PR). 2. **Sistema de Informações Rodoviárias do DNIT:** Dados cadastrais da BR-230 (Rodovia Transamazônica), atestando a extensão implantada de cerca de 4.260 km entre Cabedelo (PB) e Lábrea (AM), e os limites de quilometragem por estado (ex.: 521,0 km na Paraíba e 144,7 km no Tocantins).

1.5 Problemas Encontrados na Coleta e Resoluções Técnicas

Durante o processo de ingestão e inspeção preliminar, foram diagnosticados e solucionados três problemas técnicos essenciais:

1. **Problema com Codificação de Caracteres (*Encoding*):** Os arquivos CSV da PRF utilizam codificação `ISO-8859-1` (`latin-1`), padrão no ecossistema governamental Windows. Tentativas de leitura com o padrão `UTF-8` resultam em falha de decodificação (`UnicodeDecodeError`).
    - *Resolução:* Configuração mandatória do parâmetro `encoding='latin-1'` no leitor Pandas (`pd.read_csv`), preservando acentuações e caracteres especiais nos nomes de municípios, causas e tipos.
2. **Problema de Delimitadores e Separador Numérico Decimal:** Os arquivos são exportados com ponto e vírgula (`;`) como separador de colunas e vírgula (`,`) como separador decimal para grandezas reais (coordenadas geográficas de latitude/longitude e marco quilométrico). A leitura desatenta converte campos de coordenadas em texto (*object*), inviabilizando operações espaciais.

    - *Resolução:* Definição explícita de `sep=';'` e `decimal=','` na rotina de leitura `ler_prf()`, garantindo que latitude, longitude e quilômetro sejam carregados diretamente como números de ponto flutuante de dupla precisão (`float64`).
3. **Problema de Explosão Granular e Consumo de Memória no Arquivo Expandido:** O arquivo de causas e tipos gera multiplicação de linhas por evento. Se carregado ingenuamente para cálculo de acidentes, inflacionaria o número de ocorrências na BR-230 de 1.745 para 18.255 registros.
    - *Resolução:* Implementação de processamento por blocos iterativos (*chunksize*) com extração isolada dos identificadores únicos e criação de um pipeline que utiliza exclusivamente `datatran2025.csv` para desenhar o mapa e contar ocorrências, reservando o arquivo expandido apenas para consultas circunstanciais de causas secundárias.

---

2 Descrição dos Dados

A tarefa de descrição dos dados (*Describe data*) investiga as propriedades brutas e de superfície dos dados adquiridos. Ela documenta o formato, o volume de registros e campos, a alocação de memória RAM, a delimitação temporal, a identidade das variáveis através de um dicionário formal e avalia se o acervo atende aos requisitos do projeto.

2.1 Embalagem e Propriedades de Superfície

A tabela a seguir resume a embalagem (*packaging*) dos dados carregados na memória do ambiente de análise:

Arquivo Analisado	Registros (Linhas)	Campos (Colunas)	Acidentes Únicos (`id`)	Memória em RAM (MB)	Formato Físico
`datatran2025.csv`	72.529	30	72.529	82,5 MB	Texto CSV (delimitador ;)
`acidentes2025.csv`	194.629	35	72.529	279,3 MB	Texto CSV (delimitador ;)
`acidente`	584.010	37	72.529	~750 MB	Texto CSV

Arquivo Analisado	Registros (Linhas)	Campos (Colunas)	Acidentes Únicos (id)	Memória em RAM (MB)	Formato Físico
s2025_todas_causas_tipos.csv				(em streaming)	(delimitador ;)

O conjunto de dados apresenta uma correspondência perfeita de identificadores únicos entre as três fontes: todos os 72.529 acidentes registrados no arquivo de ocorrências encontram correspondência exata nos arquivos por pessoa e expandido, atestando a consistência do sistema de boletins da PRF.

2.2 Delimitação Temporal (Início e Fim da Base)

O intervalo temporal das ocorrências cobre o ano civil de 2025 na sua totalidade: - **Data Inicial Observada:** `2025-01-01` (primeiro registro às 06:20:00). - **Data Final Observada:** `2025-12-31` (último registro às 23:55:00). - **Distribuição Mensal:** Há registros contínuos em todos os 12 meses do ano. Na escala nacional, o volume mensal oscila entre 5.287 (fevereiro) e 6.788 (dezembro). No recorte da BR-230, as ocorrências distribuem-se estavelmente entre 120 e 160 acidentes mensais.

2.3 Grão e Relacionamento de Integridade entre as Fontes

A correta interpretação do modelo depende da distinção rigorosa da unidade amostral: 1. **Grão Ocorrência (`datatran2025.csv`):** Cada linha representa um acidente único. É o único arquivo adequado para desenhar o **Mapa de Calor** e calcular taxas de acidentes, pois não contém linhas duplicadas. 2. **Grão Pessoa (`acidentes2025.csv`):** Cada linha representa um envolvido. As colunas `mortos`, `feridos_leves`, `feridos_graves` e `ilesos` funcionam como variáveis indicadoras binárias (0 ou 1) atribuídas àquela pessoa específica. Quando essas variáveis são somadas e agrupadas por `id`, o valor reproduz exatamente as contagens das colunas de mesmo nome em `datatran2025.csv`. 3. **Grão Causas/Tipos (`acidentes2025_todas_causas_tipos.csv`):** Cada linha representa a combinação de uma pessoa, uma causa e um tipo. A filtragem por `causa_principal == 'Sim'` e `ordem_tipo_acidente == 1` restaura perfeitamente o grão de pessoa.

2.4 Dicionário de Dados Consolidado

Abaixo é apresentado o dicionário de dados formal contemplando as 41 variáveis presentes nas fontes da PRF:

Nome do Campo	Tipo Primitivo	Descrição Semântica / Negócio	Grão / Arquivo	Domínio / Exemplo
`id`	Inteiro (`int64`)	Identificador único numérico da ocorrência do acidente.	Ocorrência e Pessoa	Ex: 652493
`pesid`	Inteiro (`int64`)	Identificador único da pessoa envolvida. O valor 0 indica pessoa não identificada.	Pessoa e Expandido	Ex: 1459203 (0 = sentinela)
`data_inversa`	Texto/Data (`str`)	Data do sinistro no formato `AAAA-MM-DD`.	Ocorrência	`2025-01-01` a `2025-12-31`
`dia_semana`	Categórico (`str`)	Dia da semana da ocorrência por extenso.	Ocorrência	segunda-feira a domingo
`horario`	Texto/Hora (`str`)	Hora da ocorrência no formato `HH:MM:SS`.	Ocorrência	`00:00:00` a `23:59:59`
`uf`	Categórico (`str`)	Sigla da Unidade Federativa onde ocorreu o sinistro.	Ocorrência	PB, PA, MA, PI, AM, CE, TO

Nome do Campo	Tipo Primitivo	Descrição Semântica / Negócio	Grão / Arquivo	Domínio / Exemplo
`br`	Inteiro (`int64`)	Número identificador da rodovia federal.	Ocorrência	230 (recorte do projeto)
`km`	Real (`float64`)	Marco quilométrico do sinistro (recomeça a contagem dentro de cada UF).	Ocorrência	0,0 a 1.230,0 km
`municipio`	Categórico (`str`)	Nome do município onde o acidente aconteceu.	Ocorrência	JOAO PESSOA, MARABA, etc.
`causa_acidente`	Categórico (`str`)	Causa registrada pelo policial (causa principal em `datatran`).	Ocorrência e Expandido	Ausência de reação do condutor, etc.
`tipo_acidente`	Categórico (`str`)	Dinâmica principal do acidente (ordem 1 em `datatran`).	Ocorrência e Expandido	Colisão traseira, Tombamento, etc.
`classificacao_acidente`	Categórico (`str`)	Gravidade do acidente: Sem Vítimas, Com Vítimas Feridas ou Com Vítimas Fatais.	Ocorrência	Sem Vítimas, Feridas, Fatais

Nome do Campo	Tipo Primitivo	Descrição Semântica / Negócio	Grão / Arquivo	Domínio / Exemplo
`fase_dia`	Categórico (`str`)	Período de luminosidade natural no momento do sinistro.	Ocorrência	Pleno dia, Plena Noite, Anoitecer, Amanhecer
`sentido_via`	Categórico (`str`)	Direção de deslocamento conforme a quilometragem da via.	Ocorrência	Crescente, Decrescente, Não Informado
`condicao_metereologica`	Categórico (`str`)	Condição do tempo registrada na lavratura do boletim.	Ocorrência	Céu Claro, Nublado, Chuva, Sol, etc.
`tipo_pista`	Categórico (`str`)	Configuração estrutural da via.	Ocorrência	Simples, Dupla, Múltipla
`tracado_via`	Categórico (`str`)	Geometria do leito carroçável (pode conter valores compostos separados por ;).	Ocorrência	Reta, Curva, Reta;Declive, etc.
`uso_solo`	Categórico (`str`)	Ambiente circundante: ‘Sim’ para área urbana, ‘Não’ para área rural.	Ocorrência	Sim (Urbano), Não (Rural)
`pessoas`	Inteiro (`int64`)	Quantidade total de	Ocorrência	1 a 76 pessoas

Nome do Campo	Tipo Primitivo	Descrição Semântica / Negócio	Grão / Arquivo	Domínio / Exemplo
		pessoas envolvidas no acidente.		
`mortos`	Inteiro (`int64`)	Quantidade total de vítimas fatais no acidente (ou indicador 0/1 no arquivo pessoa).	Ocorrência / Pessoa	0 a 10 óbitos
`feridos_leves`	Inteiro (`int64`)	Quantidade de vítimas com lesões leves (ou indicador 0/1 no arquivo pessoa).	Ocorrência / Pessoa	0 a 30 feridos
`feridos_graves`	Inteiro (`int64`)	Quantidade de vítimas com lesões graves (ou indicador 0/1 no arquivo pessoa).	Ocorrência / Pessoa	0 a 20 feridos
`ilesos`	Inteiro (`int64`)	Quantidade de pessoas sem lesões físicas (ou indicador 0/1 no arquivo pessoa).	Ocorrência / Pessoa	0 a 70 pessoas
`ignorados`	Inteiro (`int64`)	Quantidade de pessoas cujo estado	Ocorrência	0 a 25 pessoas

Nome do Campo	Tipo Primitivo	Descrição Semântica / Negócio	Grão / Arquivo	Domínio / Exemplo
		físico não foi determinado.		
`feridos`	Inteiro (`int64`)	Soma aritmética de feridos leves e graves.	Ocorrência	0 a 45 feridos
`veiculos`	Inteiro (`int64`)	Quantidade total de veículos automotores envolvidos.	Ocorrência	1 a 15 veículos
`latitude`	Real (`float64`)	Coordenada geográfica em graus decimais (formato WGS84).	Ocorrência	[-2,32 a -9,75] na BR-230
`longitude`	Real (`float64`)	Coordenada geográfica em graus decimais (formato WGS84).	Ocorrência	[-34,83 a -64,95] na BR-230
`regional`	Categórico (`str`)	Superintendência da PRF responsável pela circunscrição policial.	Ocorrência	SPRF-PB, SPRF-PA, SPRF-MA, etc.
`delegacia`	Categórico (`str`)	Unidade de Delegacia da PRF circunscricionada.	Ocorrência	DEL01-PB, DEL02-PA, etc.

Nome do Campo	Tipo Primitivo	Descrição Semântica / Negócio	Grão / Arquivo	Domínio / Exemplo
`uop`	Categórico (`str`)	Unidade Operacional Policial da PRF.	Ocorrência	UOP01-PB, etc.
`id_veiculo`	Inteiro (`int64`)	Identificador do veículo vinculado à pessoa.	Pessoa	Inteiro positivo
`tipo_veiculo`	Categórico (`str`)	Categoria regulamentar do veículo do envolvido.	Pessoa	Motocicleta, Automóvel, Caminhão, etc.
`marca`	Categórico (`str`)	Fabricante e modelo comercial do veículo.	Pessoa	HONDA, VW, FIAT, etc.
`ano_fabricacao_veiculo`	Inteiro (`int64`)	Ano fabril do automóvel (o valor 0 opera como ausência).	Pessoa	1950 a 2026 (0 = sentinela)
`tipo_envolvido`	Categórico (`str`)	Função exercida pelo indivíduo no evento.	Pessoa	Condutor, Passageiro, Pedestre, etc.
`estado_fisico`	Categórico (`str`)	Gravidade clínica constatada no atendimento policial.	Pessoa	Ileso, Lesões Leves, Lesões Graves, Óbito
`idade`	Inteiro (`int64`)	Idade do indivíduo em anos	Pessoa	1 a 100 anos (0 e >100 anômalos)

Nome do Campo	Tipo Primitivo	Descrição Semântica / Negócio	Grão / Arquivo	Domínio / Exemplo
		completos (0 opera como sentinela).		
`sexo`	Categórico (`str`)	Sexo biológico declarado ou identificado.	Pessoa	Masculino, Feminino, Não Informado
`causa_principal`	Categórico (`str`)	Flag indicando se a causa foi determinante (‘Sim’ ou ‘Não’).	Expandido	Sim, Não
`ordem_tipo_acidente`	Inteiro (`int64`)	Hierarquia sequencial do tipo de impacto (1 = impacto primário).	Expandido	1 a 6

2.5 Resumo Estatístico de Superfície

Variáveis Numéricas (Escala Nacional vs. Recorte da BR-230)

A tabela abaixo exibe a distribuição univariada dos atributos contínuos e discretos na escala nacional (72.529 acidentes) e no recorte específico da BR-230 (1.745 acidentes):

Atributo Numérico	Média (BR-230)	Desvio Padrão (BR-230)	Mínimo (BR-230)	1º Quartil (25%)	Mediana (50%)	3º Quartil (75%)	Máximo (BR-230)	Média Nacional
`km`	179,9 km	240,6 km	0,0 km	25,0 km	78,0 km	231,0 km	1.230,0 km	260,0 km
`pessoas`	2,46	1,82	1,00	2,00	2,00	3,00	45,00	2,60

Atributo Numérico	Média (BR-230)	Desvio Padrão (BR-230)	Mínimo (BR-230)	1º Quartil (25%)	Mediana (50%)	3º Quartil (75%)	Máximo (BR-230)	Média Nacional
veiculos	1,67	0,81	1,00	1,00	2,00	2,00	11,00	1,74
mortos	0,110	0,39	0,00	0,00	0,00	0,00	4,00	0,083
feridos_leves	0,79	1,05	0,00	0,00	1,00	1,00	25,00	0,80
feridos_graves	0,35	0,68	0,00	0,00	0,00	1,00	7,00	0,35
ilesos	0,91	1,32	0,00	0,00	1,00	1,00	40,00	1,08
latitude	-6,71°	1,94°	-9,75°	-7,21°	-7,09°	-7,04°	-2,32°	-
longitude	-40,32°	7,85°	-64,95°	-35,88°	-35,32°	-34,88°	-34,83°	-

A mediana do quilômetro na BR-230 é de 78,0 km (com 25% dos casos situados até o km 25), demonstrando a alta concentração das ocorrências nos primeiros trechos da rodovia (em especial no litoral paraibano). A taxa média de óbitos por sinistro na BR-230 (0,110 mortes/acidente) é 32,5% superior à média nacional das rodovias federais (0,083 mortes/acidente), confirmando a severidade crítica da Rodovia Transamazônica.

Variáveis Categóricas (Recorte BR-230: 1.745 acidentes)

- **Classificação de Gravidade:** Com Vítimas Feridas (1.329 casos; 76,16%), Sem Vítimas (248 casos; 14,21%) e Com Vítimas Fatais (168 casos; 9,63%).
- **Fase do Dia:** Pleno Dia (941 casos; 53,9%), Plena Noite (634 casos; 36,3%), Anoitecer (103 casos; 5,9%) e Amanhecer (67 casos; 3,8%).
- **Condição Meteorológica:** Céu Claro (1.236 casos; 70,8%), Nublado (243 casos; 13,9%), Chuva (145 casos; 8,3%), Sol (68 casos; 3,9%), Garoa/Chuvisco (41 casos; 2,3%) e Ignorado/Nevoeiro (12 casos; 0,7%).

- **Tipo de Pista:** Pista Simples (854 casos; 48,9%), Pista Dupla (826 casos; 47,3%) e Pista Múltipla (65 casos; 3,7%).
- **Uso do Solo:** Área Urbana (`Sim`: 988 casos; 56,6%) vs. Área Rural (`Não`: 757 casos; 43,4%).
- **Sentido da Via:** Crescente (909 casos; 52,1%) e Decrescente (836 casos; 47,9%).

2.6 Avaliação do Atendimento aos Requisitos do Projeto

Confrontando os dados adquiridos com os requisitos especificados na Fase 1 (*Entendimento do Negócio*): - **Requisito de Representação Espacial:** 100% dos acidentes da BR-230 possuem pares de coordenadas (`latitude` e `longitude`) válidos e pertencentes ao território brasileiro, atendendo com excelência aos requisitos para a modelagem por Kernel Density Estimation (KDE) e visualização do **Mapa de Calor**. - **Requisito de Informações Temporais e Circunstanciais:** Data, horário, dia da semana, fase do dia, clima, geometria da via e uso do solo apresentam preenchimento pleno, viabilizando o perfilamento de risco temporal e ambiental. - **Requisito de Definição da Variável-Alvo Preditiva:** A coluna `classificacao_acidente` e as variáveis contínuas de óbitos/lesões oferecem suporte objetivo para a formulação da variável-alvo supervisionada. Constatou-se, todavia, um desbalanceamento severo da classe fatal (9,6% dos casos), o que exige salvaguardas metodológicas imediatas na fase de preparação e modelagem.

---

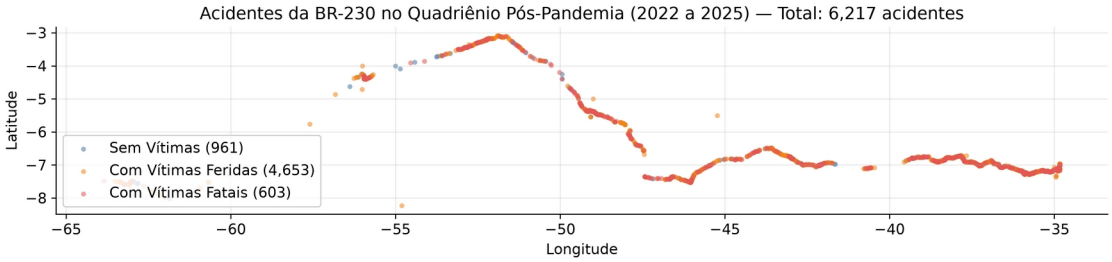
3 Exploração dos Dados

A tarefa de exploração dos dados (*Explore data*) utiliza consultas estatísticas, técnicas de visualização e agregações multidimensionais para responder às questões analíticas que orientam as metas do CRISP-DM.

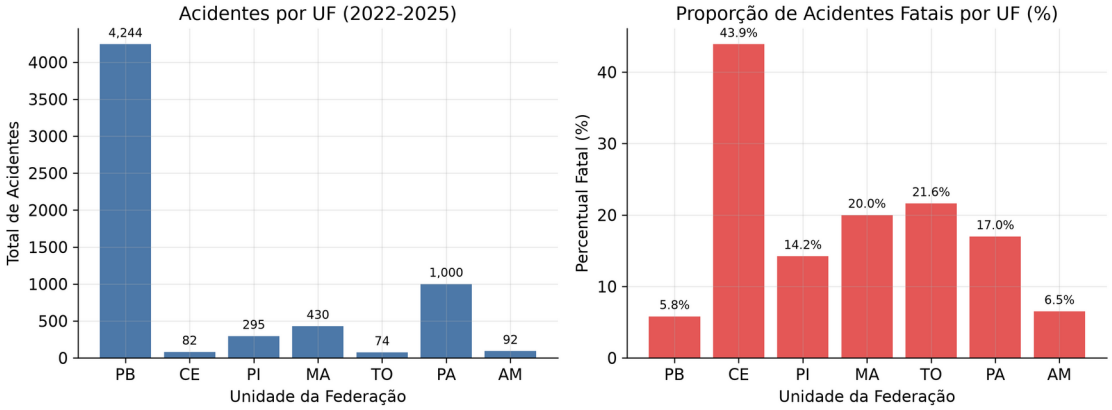
3.1 Questão 1: Concentração e Distribuição Espacial ao longo da BR-230 (Alimentação do Mapa de Calor)

Os registros da PRF de 2025 cobrem adequadamente a BR-230 no espaço geográfico? Em quais estados, municípios e trechos quilométricos os acidentes se concentram?

O corredor da BR-230 (Rodovia Transamazônica) estende-se da costa da Paraíba até o estado do Amazonas. No ano de 2025, os dados registram ocorrências em **7 Unidades da Federação** e **93 municípios distintos**.



Mapa Espacial da BR-230 no Quadriênio 2022-2025



Acidentes e Letalidade por UF na BR-230

Distribuição de Acidentes e Gravidade por Unidade da Federação na BR-230

UF	Acidentes	Participação (%)	Mortos	Feridos	Feridos Graves	Pessoas Envolvidas	Km Mínimo	Km Máximo	Municípios	Proporção Fatais (%)
PB	1.191	68,25 %	75	1.400	396	2.836	0,5 km	516,0 km	41	5,46 %
PA	280	16,05 %	55	305	92	772	2,0 km	1.230,0 km	16	16,79 %
MA	119	6,82 %	24	118	55	301	0,0 km	570,0 km	14	18,49 %
PI	88	5,04	16	82	42	192	0,0	310,4	7	15,91

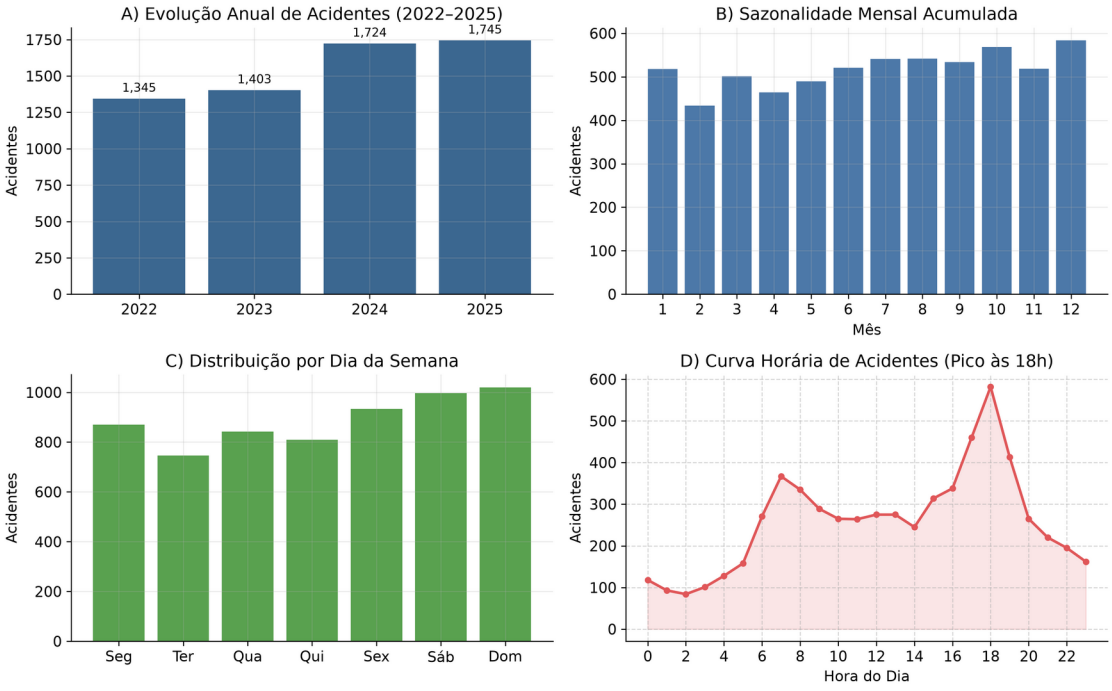
UF	Acidentes	Participação (%)	Mortos	Feridos	Feridos Graves	Pessoas Envolvidas	Km Mínimo	Km Máximo	Municípios	Proporção Fatais (%)
		%					km	km		%
AM	24	1,38 %	0	22	6	51	314,8 km	687,0 km	4	0,00 %
CE	22	1,26 %	13	19	13	57	2,2 km	113,0 km	4	54,55 %
TO	21	1,20 %	9	49	8	88	1,8 km	144,0 km	7	38,10 %
Total	**1.745**	**100,0 %**	**192**	**1.995**	**612**	**4.297**	-	-	**93**	**9,63 %**

Concentração por Faixas Quilométricas (Janelas de 50 km)

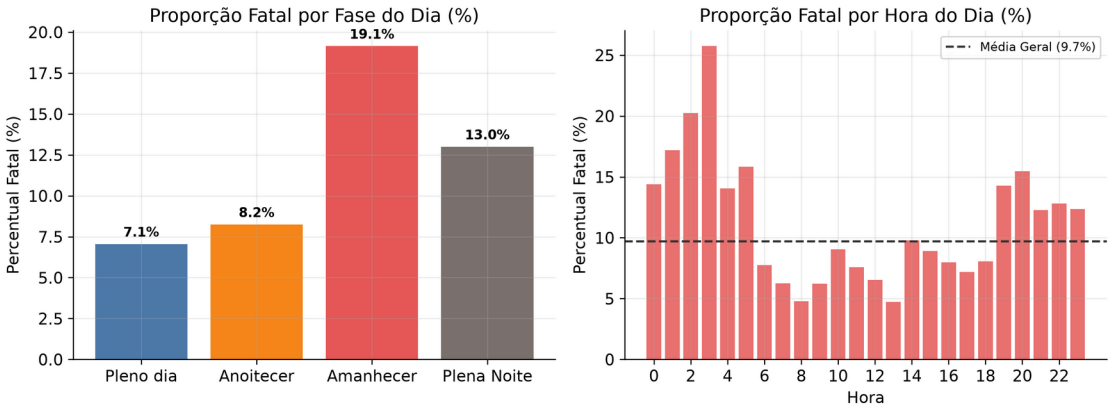
A análise espacial em janelas de 50 km revela um padrão de hiperconcentração: 1. **Faixa km 0 a 50 na Paraíba:** Concentra **649 acidentes** (37,2% de toda a BR-230 no país e 54,5% do estado da Paraíba), abrangendo os municípios de Cabedelo, João Pessoa e Santa Rita. A proporção de acidentes fatais nesta faixa é de apenas **3,39%** (22 óbitos), reflexo de uma infraestrutura urbana de pista dupla com maior tráfego, lentidão e fiscalização eletrônica. 2. **Faixa km 50 em diante na Paraíba:** Reúne 542 acidentes, com taxa de letalidade subindo para **7,93%** (53 óbitos) à medida que a rodovia avança para o agreste e sertão (Campina Grande, Patos, Sousa, Cajazeiras). 3. **Faixa km 100 no Pará:** Reúne 132 acidentes (eixo Marabá–Itupiranga), com proporção de fatalidades de **9,09%** (12 mortos).

Conclusão Espacial: A viabilidade do **Mapa de Calor** é plena. O mapa destacará com forte intensidade visual o litoral paraibano (alta densidade de eventos com baixa severidade) e núcleos urbanos do Pará e Maranhão, enquanto trechos remotos do Ceará e Tocantins apresentarão baixa densidade, mas com elevadíssimo índice de óbito por sinistro.

3.2 Questão 2: Padrões Temporais dos Acidentes (Sazonalidade, Dias e Horários)



Distribuição Temporal Consolidada da BR-230 (2022-2025)



Proporção Fatal por Fase do Dia e Horário

Quando os acidentes acontecem? Os períodos com maior volume de colisões coincidem com os momentos de maior gravidade?

Sazonalidade Mensal

O volume mensal de acidentes na BR-230 ao longo de 2025 apresenta grande estabilidade: janeiro (131), fevereiro (127), março (144), abril (139), maio (147),

junho (147), julho (150), agosto (150), setembro (145), outubro (150), novembro (149) e dezembro (166). Não se observa um mês isolado com pico desproporcional, demonstrando que a rodovia opera sob demanda contínua de tráfego.

Dia da Semana e Letalidade

Dia da Semana	Acidentes	Participação (%)	Proporção Fatais (%)	Mortos
Segunda-feira	241	13,81%	9,54%	32
Terça-feira	244	13,98%	6,56%	18
Quarta-feira	244	13,98%	9,43%	27
Quinta-feira	190	10,89%	7,89%	16
Sexta-feira	259	14,84%	6,95%	23
Sábado	292	16,73%	10,96%	32
Domingo	**285**	**16,33%**	**15,44%**	**44**

Os registros elevam-se consideravelmente a partir de sexta-feira, culminando no sábado e no domingo (que somam juntos 33,1% das ocorrências). O **domingo** é o dia de maior criticidade: concentra a maior proporção de acidentes fatais (**15,44%**) e o maior número absoluto de mortes (**44 óbitos**), indicando forte influência do lazer, excesso de velocidade e consumo de bebidas alcoólicas.

Ciclo Horário e Fase do Dia

Fase do Dia	Acidentes	Proporção do Volume (%)	Proporção de Fatais (%)	Mortos
Pleno Dia	941	53,93%	7,01%	74
Plena Noite	634	36,33%	**12,78%**	**87**
Anoitecer	103	5,90%	5,83%	7
Amanhecer	67	3,84%	**11,94%**	**11**

O ciclo horário registra pico de ocorrências entre as 17:00 e 19:00 (com máxima às 18:00 reunindo 145 acidentes), momento que coincide com a saída de

trabalhadores e fluxo pendular. Em contrapartida, a **taxa de mortalidade** é quase o dobro durante a **Plena Noite (12,78%)** e no **Amanhecer (11,94%)**, evidenciando que menor tráfego associado à escuridão e fadiga favorece colisões em velocidades mais severas.

3.3 Questão 3: Influência das Características da Via, Geometria e Condições Meteorológicas

Quais condições de infraestrutura e do ambiente meteorológico estão associadas à ocorrência de sinistros e ao aumento da gravidade?

Condição Meteorológica

O clima predominante nos boletins é de **Céu Claro** (1.236 acidentes; 70,8%), seguido por **Nublado** (243 casos; 13,9%) e **Chuva** (145 casos; 8,3%). Curiosamente, a proporção fatal em céu claro (**9,0%**) é superior à observada sob chuva (**6,9%**). Isso ocorre porque sob pista molhada e precipitação os motoristas reduzem a velocidade média, diminuindo a probabilidade de impacto fatal.

Tipo de Pista e Uso do Solo

Tipo de Pista	Acidentes	Proporção (%)	Mortos	Proporção Fatais (%)
Simples	854	48,94%	146	**14,52%**
Dupla	826	47,34%	42	**4,84%**
Múltipla	65	3,72%	4	**3,08%**

O volume de acidentes divide-se quase igualmente entre pista simples e pista dupla. Todavia, a **pista simples** concentra **76,0% de todas as mortes da rodovia** (146 dos 192 óbitos), com uma taxa de fatalidade três vezes maior do que a pista dupla (14,52% vs. 4,84%). No que tange ao ambiente, a **Área Urbana** concentra 56,6% dos acidentes (988 casos; 6,0% fatais), enquanto a **Área Rural** responde por 43,4% (757 casos; **14,4% fatais** e 131 mortes).

Geometria da Via

Acidentes em traçado de **Reta** totalizam 934 ocorrências isoladas, enquanto **Curvas** somam 131 casos. A análise identificou **536 ocorrências com traçado composto** na mesma célula (ex.: `Reta;Aclive`, `Reta;Declive`), exigindo padronização e desdobramento categórico na fase de preparação.

3.4 Questão 4: Análise da Gravidade e Definição da Variável-Alvo Preditiva

Onde os acidentes ocorrem com maior gravidade? As variáveis contextuais distinguem trechos de alto volume de trechos de alta letalidade? Como estruturar a variável-alvo preditiva?

A constatação analítica mais profunda da Fase 2 é a **dissociação entre concentração de acidentes e gravidade do desfecho**: - Onde há maior volume de acidentes (Paraíba, trecho metropolitano, pista dupla, urbano), a taxa de fatalidade é mínima (3,4%). - Onde os acidentes são menos volumosos (Norte/Nordeste interiorano, pista simples, área rural), a taxa de fatalidade atinge níveis alarmantes.

Tabela Cruzada: Uso do Solo × Tipo de Pista (Gravidade Bivariada)

Recorte Territorial	Uso do Solo	Tipo de Pista	Acidentes	Proporção Fatais (%)	Mortos
BR-230 Completa	Urbano (`Sim`)	Pista Dupla	576	4,69%	27
BR-230 Completa	Urbano (`Sim`)	Pista Simples	359	8,64%	31
BR-230 Completa	Rural (`Não`)	Pista Dupla	250	5,20%	15
BR-230 Completa	**Rural (`Não`)**	**Pista Simples**	**495**	**19,00%**	**114**
Excluindo a Paraíba	Rural (`Não`)	Pista Dupla	9	0,00%	0
Excluindo a Paraíba	Urbano (`Sim`)	Pista Dupla	96	9,38%	9

Recorte Territorial	Uso do Solo	Tipo de Pista	Acidentes	Proporção Fatais (%)	Mortos
Excluindo a Paraíba	Urbano (`Sim`)	Pista Simples	157	14,01%	23
Excluindo a Paraíba	**Rural (`Não`)**	**Pista Simples**	**291**	**24,74%**	**85**

Quando se exclui o trecho duplicado da Paraíba, o segmento **Rural em Pista Simples** apresenta **24,74% de acidentes com mortes** (1 em cada 4 acidentes resulta em óbito). No Ceará, esse valor atinge 52,63% e no Tocantins 38,10%.

Formulação da Variável-Alvo para o Componente Preditivo

Para o desenvolvimento do modelo preditivo supervisionado, estabelece-se como variável-alvo a gravidade intrínseca da ocorrência: - **Definição Operacional da Classe Positiva:** Acidente classificado como `Com Vítimas Fatais` (`mortos > 0`), representando a classe crítica de risco extremo. Alternativamente, na modelagem, pode-se avaliar o agrupamento de acidentes graves (`Com Vítimas Fatais` + `Feridos Graves`). - **Desbalanceamento de Classes:** Dos 1.745 acidentes, apenas **168 são fatais (9,63%)** contra **1.577 não-fatais (90,37%)**. Essa distribuição severamente desbalanceada (~1 positivo para cada 9,4 negativos) impõe a necessidade de reamostragem, ajuste de custos de classificação (*class weights*) e adoção de métricas apropriadas como ROC-AUC, PR-AUC, F1-macro e Acurácia Balanceada.

3.5 Questão 5: Causas Principais, Tipos de Sinistros e Perfil de Envolvidos e Veículos

Quais fatores causais e modalidades de colisão predominam? Quem são as vítimas mais afetadas e quais veículos participam dos sinistros?

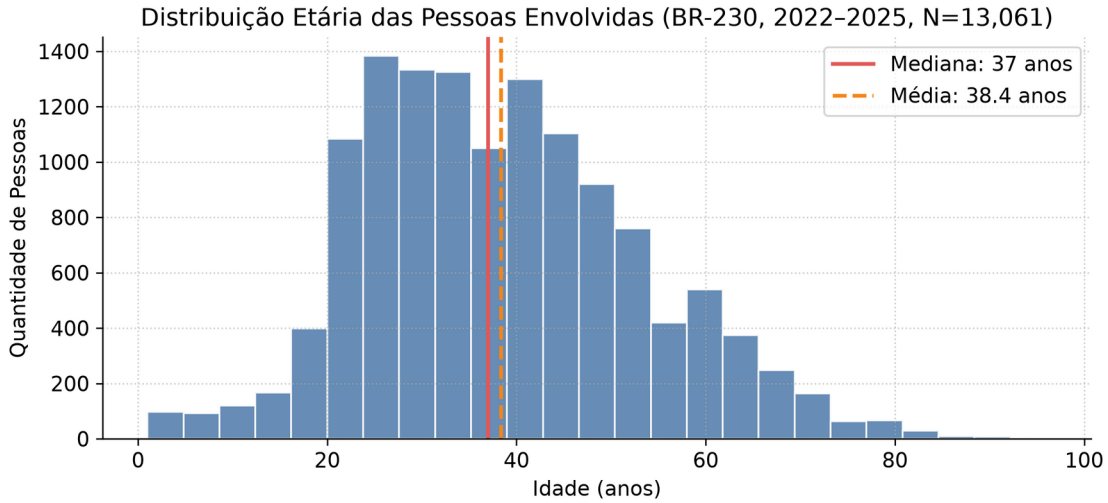
Causas Determinantes

As falhas humanas e comportamentais dominam os boletins: 1. **Ausência de reação do condutor:** 345 acidentes (19,77%). 2. **Reação tardia ou ineficiente do condutor:** 232 acidentes (13,30%). 3. **Acessar a via sem observar a presença de**

outros veículos: 168 acidentes (9,63%). 4. **Condutor deixou de manter distância segura:** 128 acidentes (7,34%). 5. **Ingestão de álcool pelo condutor:** 101 acidentes (5,79%). 6. Manobra de mudança de faixa indevida (91), Transitar na contramão (77), Falhas mecânicas/elétricas (64), Animais na pista (59), Velocidade incompatível (48) e Condutor dormindo (33).

Tipos de Acidentes

1. **Colisão traseira:** 377 acidentes (21,60%).
2. **Tombamento:** 234 acidentes (13,41%).
3. **Colisão transversal:** 230 acidentes (13,18%).
4. **Saída de leito carroçável:** 201 acidentes (11,52%).
5. **Colisão frontal:** 128 acidentes (7,34%) — modalidade responsável pela maior letalidade relativa em pista simples.



Distribuição Etária das Pessoas Envolvidas na BR-230 (2022-2025)

Perfil dos Envolvidos e Veículos (Grão Pessoa — 4.410 registros na BR-230)

- **Tipo de Envolvido:** Condutores representam a grande maioria dos registros identificados (**2.915; 65,9%**), seguidos por Passageiros (1.069; 24,2%), Testemunhas (85) e Pedestres (76).
- **Gênero:** Predomínio expressivo do sexo Masculino (**2.840; 75,6%** dos válidos) frente ao Feminino (915; 24,4%).
- **Faixa Etária:** Entre os registros com idade informada válida (1 a 91 anos), a média é de **38,4 anos** e a mediana é de **37,0 anos** (1º quartil: 27 anos; 3º quartil: 48 anos), situando a maior incidência na faixa economicamente ativa.

- **Tipo de Veículo: Motocicletas** lideram com **1.321 registros (36,1%)**, seguidas de perto por **Automóveis (1.271; 34,8%)**, Caminhonetes (422; 11,5%), Semirreboques (219), Caminhões (216) e Ônibus (178). A altíssima participação de motocicletas explica a alta taxa de ferimentos graves e óbitos na região.

---

4 Qualidade dos Dados

A tarefa de verificação da qualidade (*Verify data quality*) avalia se a base cobre todos os casos requeridos, detecta erros, ruídos e inconsistências lógicas, quantifica e rastreia os valores ausentes e formaliza a matriz de decisões e encaminhamentos para a etapa de Preparação dos Dados (*Data Preparation*).

4.1 Completude dos Dados

- **Completude Espacial e Temporal da BR-230:** A base de acidentes da PRF de 2025 cobre com 100% de completude as coordenadas geográficas (`latitude` e `longitude`), o quilômetro da via, a data e a classificação de gravidade para todos os 1.745 registros da BR-230.
- **Limitação de Amostragem em Trechos Remotos:** Em estados como Ceará (22 acidentes), Tocantins (21 acidentes) e Amazonas (24 acidentes), a baixa contagem em 2025 decorre da baixa densidade de tráfego e trechos de difícil fiscalização. Municípios como Lábrea (AM), extremo oeste da rodovia, não possuem registros de acidentes no ano, o que reflete a ausência de sinistros comunicados e não uma falha de extração.
- **Limitação Estrutural de Escopo (Ausência de Dados de Exposição):** A base da PRF é composta estritamente por *ocorrências consumadas* (numerador do risco). Ela não inclui contagens de fluxo de tráfego (Volume Médio Diário — VMD) nem gera registros de "não-acidentes" para trechos e horários seguros. Assim, os modelos probabilísticos desenvolvidos representarão o **risco condicional à ocorrência de um acidente** (probabilidade de severidade fatal dado que o acidente ocorreu), complementando o **Mapa de Calor** que estima a densidade espacial das ocorrências.

4.2 Correção e Identificação de Erros Lógicos

A investigação detalhada revelou anomalias que exigem tratamento na Fase 3: 1. **Identificador Sentinela `pesid = 0`:** Constatou-se a existência de **263 linhas com `pesid = 0`** na BR-230. Trata-se de um código sentinela utilizado pela PRF para registrar indivíduos não identificados (como condutores evadidos ou vítimas sem documentação). Como o mesmo `pesid = 0` é atribuído a diferentes pessoas em um mesmo acidente, isso gerava a falsa impressão de linhas duplicadas (113 linhas além do número de pessoas distintas). O valor 0 deve ser tratado como ausência de ID pessoal. 2. **Idades e Anos de Fabricação Sentinela:** Foram identificadas **753 linhas com `idade = 0`** e **567 linhas com `ano_fabricacao_veiculo = 0`**. Ambos operam como códigos de omissão de informação e não valores numéricos reais. Além disso, identificou-se um registro com idade de 914 anos (erro grosseiro de digitação). 3. **Discrepância na Soma de Envolvidos:** Em 65 acidentes na BR-230, a soma de `mortos + feridos_leves + feridos_graves + ilesos + ignorados` diverge sutilmente da coluna `pessoas`. A coluna `pessoas` deve ser adotada como contagem de referência primária por coincidir com a contagem de registros no arquivo por pessoa. 4. **Divergência Administrativa vs. Geográfica:** Em 34 acidentes, a Unidade Federativa do município onde ocorreu o sinistro difere da UF da Superintendência Regional da PRF responsável pelo boletim. O caso mais frequente ocorre na divisa entre Maranhão e Piauí (municípios maranhenses da BR-230 atendidos pela SPRF-PI). Para a confecção do mapa e análise geoespacial, as coordenadas geográficas e a UF do município prevalecem de forma soberana sobre a circunscrição administrativa. 5. **Traçados Compostos de Pista:** O campo `tracado_via` possui **536 registros** contendo múltiplos valores separados por ponto e vírgula na mesma célula (ex.: `Reta;Aclive`).

4.3 Valores Ausentes

A tabela a seguir consolida a taxa de incompletude e valores ausentes (*missing values*) nas três fontes:

Arquivo	Atributo	Quantidade Nula / Percentual	Diagnóstico e Impacto no Projeto
`datatran2025.csv`	`uop`	38 ausências (0,05% nacional)	Metadado administrativo policial; sem impacto

Arquivo	Atributo	Quantidade Nula / Percentual	Diagnóstico e Impacto no Projeto
			analítico.
datatran2025.csv	delegacia	22 ausências (0,03% nacional)	Metadado administrativo policial; sem impacto analítico.
datatran2025.csv	regional	2 ausências (<0,01% nacional)	Metadado administrativo policial; sem impacto analítico.
datatran2025.csv	classificacao_acidente	1 ausência (0 na BR-230)	Na BR-230 a completude é de 100,0%.
datatran2025.csv	latitude, longitude, km	0 ausências na BR-230 (100% preenchidos)	Excelente cobertura espacial; nenhum registro da BR-230 é descartado por falta de coordenada.
acidentes2025.csv	tipo_envolvido, estado_fisico, sexo	8,81% de nulos na base nacional	Decorre de vítimas não identificadas ou que evadiram do local.
acidentes2025.csv	tipo_veiculo	3,26% de nulos na base nacional	Ocorrências com pedestres/animais ou veículos não identificados.
expandidos	idade	18,08% de nulos na base nacional	Exige imputação robusta ou exclusão de

Arquivo	Atributo	Quantidade Nula / Percentual	Diagnóstico e Impacto no Projeto
			modelos específicos de condutor.
`expandidos`	`pesid`	9,73% de nulos na base nacional	Pessoas sem identificação formal.

4.4 Validação Externa dos Dados

Para garantir a higidez e a consistência científica dos dados manipulados, realizou-se a validação cruzada externa confrontando os totais calculados no ambiente analítico contra fontes oficiais externas.

Confronto com o Anuário Estatístico 2025 da PRF

Indicador de Controle	Valor no Anuário Oficial PRF 2025	Total Calculado na Base Local	Status da Validação
Total Nacional de Sinistros em 2025	72.529	72.529	**Conferência Exata (100%)**
Total Nacional de Vítimas Fatais (Óbitos)	6.043	6.043	**Conferência Exata (100%)**
Total Nacional de Feridos	83.550	83.550	**Conferência Exata (100%)**
Sinistros na Rodovia BR-101	13.014	13.014	**Conferência Exata (100%)**
Sinistros na Rodovia BR-116	11.021	11.021	**Conferência Exata (100%)**
Sinistros na Rodovia	3.502	3.502	**Conferência Exata (100%)**

Indicador de Controle	Valor no Anuário Oficial PRF 2025	Total Calculado na Base Local	Status da Validação
BR-040			
Sinistros no Estado de Minas Gerais	9.570	9.570	**Conferência Exata (100%)**
Sinistros no Estado de Santa Catarina	8.186	8.186	**Conferência Exata (100%)**
Sinistros no Estado do Paraná	7.630	7.630	**Conferência Exata (100%)**

A igualdade estrita em todos os 9 indicadores atesta que o arquivo `datatran2025.csv` utilizado no projeto é a extração consolidada e definitiva do fechamento de 2025 da PRF.

Confronto com a Infraestrutura Rodoviária do DNIT

- **Limite Quilométrico da Paraíba:** O maior quilômetro registrado com acidente na PB é o **km 516,0**, valor perfeitamente compatível e contido no limite oficial publicado pelo DNIT de **521,0 km** para o trecho paraibano.
- **Limite Quilométrico do Tocantins:** O maior quilômetro com acidente no TO é o **km 144,0**, contido na extensão oficial do trecho tocantinense de **144,7 km**.

4.5 Matriz de Encaminhamentos e Decisões para a Fase 3 (Preparação dos Dados)

A tabela abaixo estabelece as decisões técnicas obrigatórias a serem implementadas no pipeline da Fase 3 (*Data Preparation*), conectando os diagnósticos de qualidade aos objetivos de negócio:

Decisão Técnica para a Fase 3	Justificativa Metodológica	Tratamento / Implementação no Pipeline
1. Utilizar `datatran2025.csv` como	Cada linha representa exatamente um acidente,	Filtrar `br == 230` mantendo a unidade de

Decisão Técnica para a Fase 3	Justificativa Metodológica	Tratamento / Implementação no Pipeline
base do Mapa de Calor e modelo primário	com 100% de coordenadas preenchidas.	análise de ocorrência única.
2. Utilizar `acidentes2025.csv` apenas para agregação de vítimas e veículos	O grão é o indivíduo. Somar flags binárias por `id` evita duplicação de acidentes.	Criar atributos agregados por acidente (ex.: `% de motocicletas`, `presença de pedestre`).
3. Posicionamento geográfico estritamente por (`latitude`, `longitude`)	O quilômetro (`km`) recomeça a contagem dentro de cada estado da federação.	Utilizar coordenadas WGS84 para agrupamento espacial e densidade Kernel (KDE).
4. Tratar `pesid = 0`, `idade = 0` e `ano_fabricacao_veiculo = 0` como valores ausentes (`NaN`)	Representam valores sentinela de omissão e não valores numéricos reais.	Substituir zeros sentinela por `NaN` e aplicar imputação por mediana ou categoria específica.
5. Desmembrar o atributo `tracado_via` com valores compostos	536 registros possuem traçados combinados por ponto e vírgula (`Reta;Declive`).	Criar variáveis *dummy* ou selecionar a primeira geometria como predominante.
6. Preservar as coordenadas e UF do município em casos de divergência administrativa	Em 34 registros a regional administrativa difere do local geográfico do fato.	A localização física do sinistro sobrepõe-se à jurisdição policial para fins de mapeamento.
7. Estruturar tratamento especializado para o desbalanceamento da classe fatal	Apenas 9,63% dos sinistros da BR-230 resultaram em mortes (168 de 1.745).	Adotar pesos balanceados (*class_weight='balanced'*), técnicas de *oversampling* (SMOTE) e métricas PR-AUC / F1-Score.
8. Modelar a probabilidade condicional de risco	A base não contém volumes de veículos em trânsito (não-acidentes).	O modelo prediz a severidade condicional ao acidente ocorrido; o

Decisão Técnica para a Fase 3	Justificativa Metodológica	Tratamento / Implementação no Pipeline
		mapa expressa a concentração espacial.

5 Referências

1. **Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R.** (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. CRISP-DM Consortium.
2. **Polícia Rodoviária Federal (PRF).** (2026). *Dados Abertos da PRF: Acidentes de Trânsito*. Ministério da Justiça e Segurança Pública. Disponível em: https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dados-abertos-da-prf.
3. **Polícia Rodoviária Federal (PRF).** (2026). *Dicionário de Dados de Acidentes de Trânsito*. Disponível em: https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dicionario-acidentes.
4. **Polícia Rodoviária Federal (PRF).** (2026). *Anuário Estatístico 2025 da Polícia Rodoviária Federal*. Divulgado em Maio de 2026. Disponível em: https://www.gov.br/prf/pt-br/noticias/nacionais/2026/maio/prf-divulga-anuario-estatistico-de-2025-com-aumento-de-infracoes-e-reducao-de-mortes-nas-rodovias-federais.
5. **Departamento Nacional de Infraestrutura de Transportes (DNIT).** (2026). *Informações Rodoviárias e Extensões da Rodovia BR-230*. Ministério dos Transportes. Disponível em: https://www.gov.br/dnit/pt-br.
6. **Behboudi, L., et al.** (2024). *Machine Learning and Spatial Analysis for Road Traffic Accident Prediction*. Journal of Safety Research.
7. **Santos, D., et al.** (2021). *Spatial analysis and accident hotspot identification on federal highways*. Transportation Research Interdisciplinary Perspectives.
8. **Tozetto, R., et al.** (2025). *Spatio-temporal modeling of traffic crashes using open federal highway data in Brazil*. Accident Analysis & Prevention.