UNIVERSIDADE FEDERAL DO MARANHÃO
CENTRO DE CIÊNCIAS EXATAS E TECNOLOGIA
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

Relatório Técnico de Preparação dos Dados

Fase 3 do Modelo CRISP-DM

Taxonomia de Escalas, Medidas de Forma, Diagnóstico de Outliers e Engenharia de Preditores para a Rodovia BR-230

DISCIPLINA: CIÊNCIA DE DADOS — PROF. LUCIANO REIS COUTINHO

Autores:

João Batista Santos Silva Neto
Ricardo Diniz Mendes
Winy Gabrielly Soares de Oliveira

São Luís – MA
2026

Histórico de Revisões do Documento

Rev.	Descrição das Modificações	Modificado por	Status	Data
1.0	Elaboração do Relatório da Fase de Preparação dos Dados: base BR-230 2022–2025, taxonomia de Stevens e EDA (Aula 4), limpezas, atributos derivados, *One-Hot Encoding* com imputação sem vazamento, partição prospectiva, matrizes X/y e camada geoespacial GeoJSON, com artefatos em `bases/preparadas/`.	Equipe do projeto	Concluído	03/11/2026

1 Introdução e Enquadramento Metodológico

O modelo de referência CRISP-DM (*Cross-Industry Standard Process for Data Mining*) estrutura o ciclo de vida da ciência de dados em fases iterativas e dependentes [1]. No desenvolvimento do projeto da rodovia BR-230 (Transamazônica), as fases de **Entendimento dos Dados** (Fase 2) e **Preparação dos Dados** (Fase 3) operam em estreita simbiose:

1. A Fase 2 investiga as fontes disponíveis, descreve sua estrutura, realiza a **Análise Exploratória dos Dados (EDA)** e avalia a qualidade da informação, conforme delineado na Aula 4 da disciplina de Ciência de Dados do PPGCC/UFMA.
2. A Fase 3 materializa os diagnósticos e decisões analíticas por meio de transformações concretas: **formatação**, **seleção**, **limpeza**, **construção de atributos** e **integração**, culminando na criação das matrizes de treino e teste para os algoritmos de aprendizado de máquina da Fase 4 (Modelagem).

O objetivo de negócio, estabelecido na Fase 1, consiste em associar a densidade histórica de ocorrências (mapa de calor por intensidade pontual) com um classificador preditivo capaz de estimar a probabilidade condicional de letalidade de um sinistro dado o contexto viário e ambiental:

$$P(\text{Fatal} = 1 \mid \text{Acidente}, \text{contexto viário, temporal e ambiental}).$$

A base da Polícia Rodoviária Federal (PRF) registra o universo de acidentes atendidos pela corporação, porém carece de contadores contínuos de Volume Médio Diário (VMD). Portanto, a variável-alvo modelada é a severidade do acidente (letalidade condicional), e não a taxa de exposição por veículo-quilômetro.

O recorte empírico adotado abrange a série histórica pós-pandemia de **2022 a 2025** na rodovia **BR-230**, totalizando **6.217 acidentes** catalogados e **603 ocorrências com vítimas fatais** (taxa média de 9,70%).

2 Taxonomia de Dados e Escalas de Medida

Conforme enfatizado na Aula 4, é fundamental distinguir o **tipo computacional** do dado (`INTEGER`, `FLOAT`, `VARCHAR`, `DATE`) do seu **tipo de escala de medida** (taxonomia de Stevens: Nominal, Ordinal, Intervalar e Razão). A escala de medida determina rigorosamente:

- As relações matemáticas e operadores analíticos válidos ($=, \neq, <, >, -, \div$);
- As transformações admissíveis sem distorção ou perda semântica da informação (Razão $\rightarrow$ Intervalar $\rightarrow$ Ordinal $\rightarrow$ Nominal);
- As medidas estatísticas de posição, variabilidade e forma cujo cálculo é matematicamente cabível.

A Tabela 1 cataloga os atributos do projeto de acordo com essa hierarquia formal.

Tabela 1: Taxonomia e escalas de medida dos atributos do projeto BR-230 (conforme Aula 4).

Atributo	**Tipo Físico**	**Escala**	**Operações Válidas**	**Estatísticas Cabíveis / Papel**
`id`	`int64`	Nominal	$=, \neq$	Chave primária de integridade
`uf`, `municipio`	`object`	Nominal	$=, \neq$	Moda, frequência absoluta/relativa
`tipo_pista`, `tracado`	`object`	Nominal	$=, \neq$	Moda, tabelas de contingência
`condicao_meteo`	`object`	Nominal	$=, \neq$	Preditores contextuais de via
`fase_dia`	`object`	Ordinal	$=, \neq, <, >$	Mediana, quantis, moda (ranking diurno)
`gravidade`	`object`	Ordinal	$=, \neq, <, >$	Sem vítimas $<$ com feridos $<$ fatal
`data`, `horario`	`datetime64`	Intervalar	$=, \neq, <, >, -$	Diferença de tempo (zero arbitrário/UTC)
`km`, `km_ajustado`	`float64`	Razão	$=, \neq, <, >, -, \div$	Média, desvio, CV, IQR, skewness
`hora` (0–23)	`int64`	Intervalar / Razão	$=, \neq, <, >, -$	Média circular/linear, dispersão horária
`idade_media`	`float64`	Razão	$=, \neq, <, >, -, \div$	Média, desvio, quartis (zero absoluto)
`mortos`, `feridos`	`int64`	Razão	$=, \neq, <, >, -, \div$	Contagem absoluta de vítimas
`alvo_fatal`	`int64` (0/1)	Binária (Nom.)	$=, \neq$	Proporção (p), taxa de letalidade

Implicação direta para a modelagem: Variáveis nominais de alta cardinalidade (`municipio`, `tracado_via`) não permitem ordenação direta e exigiram redução semântica (como o isolamento do `tracado_principal` e agrupamentos regionais). Por sua vez, atributos em escala de razão (`km`, `idade`) suportam parametrizações estatísticas e auditorias de valores atípicos.

3 Análise Exploratória dos Dados (EDA)

Em conformidade com as diretrizes da Aula 4, a exploração dos dados compreende a computação sistemática de medidas estatísticas de centro, dispersão e forma, a identificação formal de *outliers* e a análise bivariada de distribuições conjuntas.

3.1 Medidas de tendência central, dispersão e forma

A Tabela 2 resume o perfil estatístico dos preditores contínuos e métricos da BR-230.

Tabela 2: Sumário estatístico dos atributos métricos da BR-230 (série 2022–2025).

Métrica Estatística	**Quilômetro**	**Hora**	**Idade Média**	**Mortos**	**Feridos**
Tamanho amostral (n)	6.217	6.217	5.978	6.217	6.217
Média aritmética ($\bar{x}$)	185,47 km	13,09 h	38,79 anos	0,109	1,138
Mediana (Md)	117,00 km	14,00 h	38,00 anos	0,000	1,000
Moda (Mo)	19,00 km	18,00 h	35,00 anos	0	1
Ponto Médio ($\frac{\min+\max}{2}$)	735,00 km	11,50 h	46,50 anos	3,000	16,500
Mínimo / Máximo	0,0 / 1.470,0	0 / 23	9,0 / 84,0	0 / 6	0 / 33
Amplitude total (A)	1.470,00 km	23,00 h	75,00 anos	6	33
Desvio Padrão (s)	223,04 km	5,92 h	11,19 anos	0,360	1,155
Variância (s^2)	49.748,69	35,01	125,14	0,130	1,334
Coeficiente de Variação (CV)	**1,203**	0,452	**0,288**	3,312	1,015
1º Quartil (Q_1)	23,00 km	8,00 h	30,50 anos	0,000	1,000
3º Quartil (Q_3)	281,30 km	18,00 h	46,00 anos	0,000	1,000
Distância Interquartil (IQR)	258,30 km	10,00 h	15,50 anos	0,000	0,000
Assimetria de Fisher (γ)	**+2,009**	**–0,310**	**+0,534**	**+4,412**	**+8,677**
Curtose de Fisher (β)	**+4,766**	**–0,889**	**+0,198**	**+31,305**	**+186,04**

Interpretação analítica dos achados (Aula 4):

- **Quilômetro (`km`):** Exibe assimetria fortemente positiva ($\gamma = +2,01$) e distribuição marcadamente leptocúrtica ($\beta = +4,77$), com $CV = 1,20$ (elevada dispersão relativa). A média ($\bar{x} = 185,5$) supera substancialmente a mediana ($Md = 117,0$), o que reflete a enorme concentração de sinistros nos trechos metropolitanos iniciais da Paraíba (km 0 a 150) e uma longa cauda nos trechos remotos do Pará e Amazonas (até km 1.470).
- **Hora do dia:** Apresenta assimetria ligeiramente negativa ($\gamma = -0,31$) e perfil platicúrtico ($\beta = -0,89$). A dispersão é ampla e moderadamente homogênea ($CV = 0,45$), com pico modal no final da tarde (18h) e pico secundário matutino.
- **Idade média dos envolvidos:** Apresenta $CV = 0,288$ (baixa variabilidade relativa) e aproxima-se de uma distribuição normal/mesocúrtica ($\gamma = +0,53$, $\beta = +0,20$), centrada em 38,8 anos, sem distorções severas de cauda após o expurgo das idades sentinela.
- **Contagem de mortos:** Possui assimetria extrema ($\gamma = +4,41$) e curtose aguda ($\beta = +31,31$), atestando que acidentes fatais constituem um evento severamente desbalanceado (90,3% das ocorrências têm 0 mortos).

3.2 Detecção formal de outliers (Valores anômalos)

A Aula 4 prescreve dois critérios canônicos para auditoria de pontos fora da curva:

1. **Regra Empírica da Amplitude:** Pontos externos ao intervalo $\bar{x} \pm 2s$ (ou $\pm 3s$);
2. **Regra dos Quartis de Tukey (Boxplot):** Pontos abaixo de $Q_1 - 1,5 \times$ IQR ou acima de $Q_3 + 1,5 \times$ IQR.

A Tabela 3 compara os resultados de ambos os métodos sobre os dados da BR-230 com formatação balanceada.

Tabela 3: Comparação formal de detecção de outliers (Regra Empírica vs. Critério de Tukey).

Atributo	**Regra Empírica ($\bar{x} \pm 2s$)**	**Critério de Tukey ($1,5 \times$ IQR)**	**Diagnóstico e Tratamento no Pipeline**
`km_ajustado`	$[-260,6; 631,6]$ km **262 outliers** (4,21%)	$[-364,5; 668,8]$ km **227 outliers** (3,65%)	Trechos autênticos do Pará e Amazonas (até km 1.470). Preservados integralmente; o efeito regional é modelado via `fora_pb`.
`hora`	$[1,3; 24,9]$ h **211 outliers** (3,39%)	$[-7,0; 33,0]$ h **0 outliers** (0,00%)	Ciclo de 24 horas legítimo; nenhuma exclusão. O critério de Tukey atesta normalidade operacional do registro.
`idade_media`	$[16,4; 61,2]$ anos **232 outliers** (3,88%)	$[7,3; 69,3]$ anos **45 outliers** (0,75%)	Idades atípicas válidas (crianças e idosos); mantidas na base. Casos com 0 sentinela foram tratados previamente.
`mortos`	$[-0,61; 0,83]$ **603 outliers** (9,70%)	$[0,00; 0,00]$ **603 outliers** (9,70%)	Coincide estritamente com os 603 sinistros fatais; compõe a classe minoritária da variável-alvo.

Decisão de Engenharia de Dados: Nenhum acidente foi expurgado com base pura em quilometragem atípica. Como demonstrado na Fase 2, os valores de km acima de 668 km correspondem à extensão real da BR-230 no estado do Pará (que alcança o km 1.470). O modelo preditivo captura essa heterogeneidade espacial através do atributo binário derivado `fora_pb`.

3.3 Análise bivariada e distribuições conjuntas

A distribuição conjunta de frequências (Aula 4, Slide 31) analisa a dependência estocástica entre fatores de risco viário/ambiental e a letalidade. A Tabela 4 consolida os cruzamentos bivariados frente ao alvo preditivo.

Tabela 4: Distribuição conjunta bivariada dos preditores contextuais frente à letalidade.

Fator de Risco Analisado	Total de Ocorrências	Freq. Relativa (%)	Ocorrências Fatais	Taxa de Letalidade (%)
Tipo de Pista				
Pista Simples	3.170	50,99%	452	**14,26%**
Pista Dupla	2.865	46,08%	145	5,06%
Pista Múltipla	182	2,93%	6	3,30%
Fase do Dia				
Amanhecer	235	3,78%	45	**19,15%**
Plena Noite	2.208	35,52%	287	**13,00%**
Anoitecer	388	6,24%	32	8,25%
Pleno Dia	3.386	54,46%	239	7,06%
Uso do Solo (Ambiente)				
Área Rural (`area_rural=1`)	2.778	44,68%	410	**14,76%**
Área Urbana (`area_urbana=1`)	3.439	55,32%	193	5,61%
Localização Geográfica				
Trecho Paraibano (PB)	4.244	68,26%	247	5,82%
Trecho Fora da PB (PA, MA, PI, TO, AM, CE)	1.973	31,74%	356	**18,04%**

A taxa de letalidade em pista simples (14,26%) é quase o triplo da observada em pista dupla (5,06%). Em trechos rurais fora da Paraíba com pista simples durante a noite ou amanhecer, a probabilidade empírica de óbito ultrapassa 25%, fundamentando os atributos construídos na Seção 7.

3.4 Visualização gráfica da exploração

A Figura 1 sintetiza três representações gráficas essenciais recomendadas na Aula 4: os boxplots de dispersão por subpopulação regional, o polígono acumulado (ogiva) de horários e o mapa de calor de contingência bivariada.

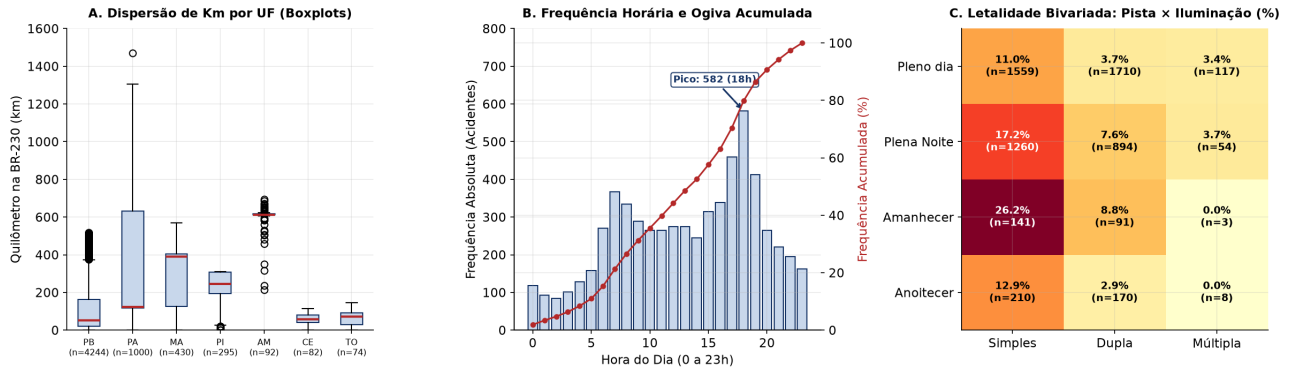


Figura 1: Análise Exploratória dos Dados (EDA): (A) Boxplots de dispersão e identificação de *outliers* de km por UF; (B) Distribuição de frequências e Ogiva Acumulada de horário; (C) Distribuição bivariada e taxa de letalidade por tipo de pista e iluminação na BR-230.

- **Painel A (Boxplots):** Demonstra a alta compacidade dos acidentes na Paraíba (IQR estreito, de 20 a 162 km) contrastando com a vasta extensão e variabilidade quilométrica no Pará (com amplitude de até 1.470 km e mediana em 122 km).
- **Painel B (Ogiva Horária):** A curva ogiva evidencia que 50% dos sinistros ocorrem até as 14h, com forte gradiente de aceleração acumulada entre as 16h e as 20h.
- **Painel C (Matriz Bivariada):** A intensidade cromática destaca que a conjunção de pista simples com o amanhecer atinge 26,2% de fatalidade, enquanto pista dupla em pleno dia registra apenas 3,7%.

3.5 Distribuições de frequência e gráfico de Pareto

A Aula 4 prescreve a distribuição de frequências em três formas: absoluta, relativa e acumulada. A Tabela 5 apresenta as oito principais causas de acidente da BR-230, e a Figura 2 mostra o respectivo gráfico de Pareto, o histograma com polígono de frequência do quilômetro e a participação por fase do dia.

Tabela 5: Distribuição de frequências das oito principais causas de acidente (BR-230, 2022–2025, $n = 6.217$).

Causa do acidente	Freq. absoluta	Freq. relativa (%)	Freq. acumulada (%)
Ausência de reação do condutor	1.062	17,08	17,08
Reação tardia ou ineficiente do condutor	850	13,67	30,75
Acessar a via sem observar a presença dos outros veículos	632	10,17	40,92
Condutor deixou de manter distância do veículo da frente	455	7,32	48,24
Ingestão de álcool pelo condutor	360	5,79	54,03
Manobra de mudança de faixa	346	5,57	59,59
Transitar na contramão	301	4,84	64,44
Velocidade incompatível	222	3,57	68,01

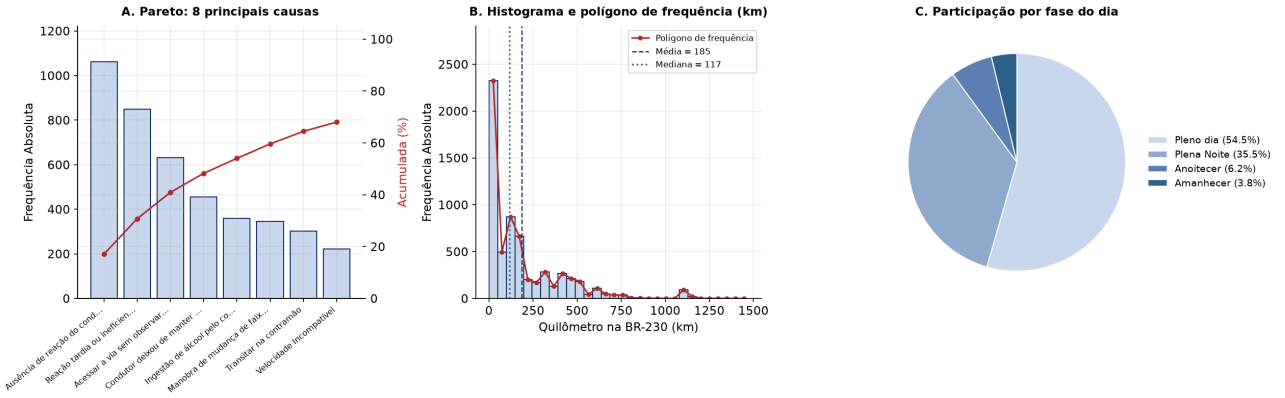


Figura 2: (A) Pareto das oito principais causas; (B) histograma e polígono de frequência do quilômetro, com média (185 km) e mediana (117 km); (C) participação dos acidentes por fase do dia.

- **Pareto:** oito causas explicam 68,0% dos acidentes, e as falhas de atenção e reação do condutor (as duas primeiras) respondem sozinhas por 30,8%.
- **Quilômetro:** a distribuição é assimétrica à direita (média $>$ mediana) e concentra-se nos primeiros 200 km, que correspondem ao entorno da Grande João Pessoa.
- **Fase do dia:** 54,5% dos acidentes ocorrem em pleno dia e 35,5% em plena noite, mas a letalidade noturna é bem superior (13,0% contra 7,1%).
- **Demais atributos:** a colisão traseira é o tipo mais frequente (20,5%); 70,6% dos registros ocorrem com céu claro; domingo e sábado concentram 32,5% dos acidentes.

3.6 Medidas complementares e comparação de regras de outlier

Complementamos o sumário da seção anterior com as medidas da Aula 4 ainda não calculadas (moda, ponto médio, amplitude, variância e coeficiente de variação $CV = s/\bar{x}$) e comparamos a regra empírica de 2σ com a regra de Tukey (Tabela 6).

Tabela 6: Medidas complementares e contagem de outliers por duas regras.

Atributo	Moda	Pto. médio	Ampl.	Variância	CV	Outl. 2σ	Outl. Tukey
`km`	23	735,0	1.470	49.748,7	1,20	262 (4,2%)	227 (3,7%)
`hora`	18	11,5	23	35,0	0,45	211 (3,4%)	0 (0,0%)
`pessoas`	2	25,5	49	3,6	0,77	111 (1,8%)	432 (7,0%)
`veiculos`	2	11,5	21	0,9	0,51	315 (5,1%)	315 (5,1%)
`feridos`	1	16,5	33	1,3	1,01	145 (2,3%)	2.887 (46,4%)
`mortos`	0	3,0	6	0,13	3,31	603 (9,7%)	603 (9,7%)

As duas regras divergem muito em atributos de contagem com mediana próxima do primeiro quartil: em `feridos`, Tukey marca 46,4% dos registros como anômalos porque o IQR é nulo, enquanto 2σ marca 2,3%. Esses valores são ocorrências reais (acidentes com múltiplos feridos) e não erros, portanto **nenhum outlier foi removido**. Em `mortos`, os 603 "outliers" são exatamente os acidentes fatais, isto é, a classe-alvo. O coeficiente de variação de `mortos` (3,31) confirma a natureza rara e muito dispersa do desfecho.

3.7 Análise multivariada

A Figura 3 apresenta a matriz de correlação de Pearson entre os atributos métricos e o indicador de óbito, e o mapa de calor de dia da semana × faixa horária (três dimensões: dia, hora e volume).

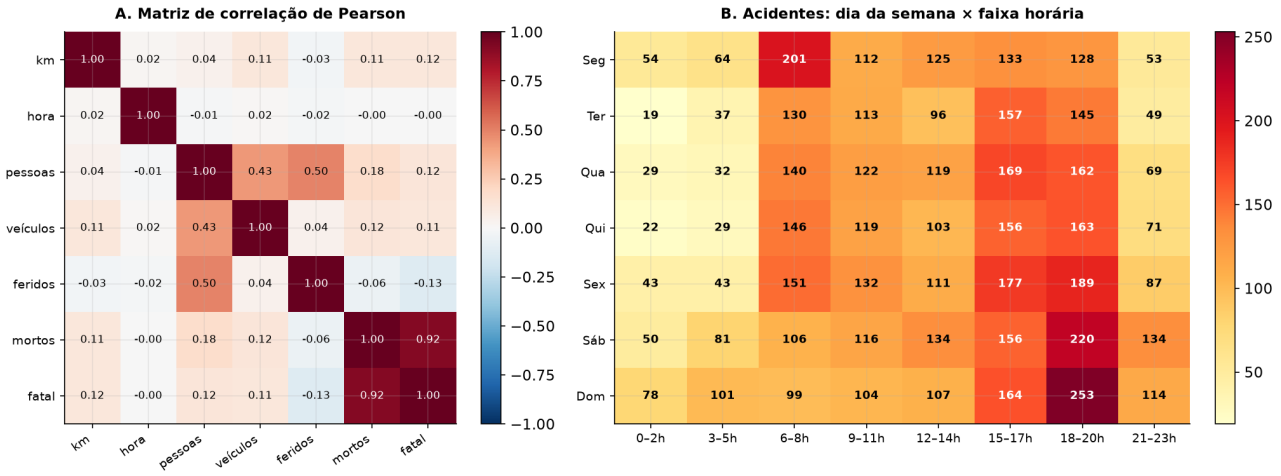


Figura 3: (A) Correlação de Pearson entre atributos métricos e óbito; (B) acidentes por dia da semana e faixa horária.

- **Correlação:** a única correlação forte é `mortos` × óbito ($r = 0,92$), o que é esperado, pois o alvo é derivado de `mortos`. Isso justifica a exclusão de `mortos` dos preditores (prevenção de vazamento). As demais associações são fracas ou moderadas: `pessoas` × `feridos` $(0,50)$ e `pessoas` × `veículos` $(0,43)$.
- **Dia × hora:** o maior volume ocorre aos domingos das 18h às 20h (253 acidentes), seguido de sábado no mesmo horário (220) e de segunda-feira de manhã (201, 6h–8h). A madrugada de fim de semana também é mais intensa do que a dos dias úteis.

3.8 Sub-populações e inferência estatística

Os 6.217 registros são tratados como amostra do processo gerador de acidentes. A letalidade geral é de 9,70% com intervalo de confiança de 95% (Wilson) de $[8,99\%;\ 10,46\%]$. A Tabela 7 detalha a letalidade por sub-população, e as Tabelas 8 e 9 trazem os testes de independência e as razões de chances.

Tabela 7: Letalidade por sub-população com intervalo de confiança de 95% (Wilson).

Sub-população	n	**Fatais**	**Letalidade (%)**	**IC 95% (%)**
Pista simples	3.170	452	14,26	13,08–15,52
Pista dupla	2.865	145	5,06	4,32–5,93
Rural	2.778	410	14,76	13,49–16,13
Urbano	3.439	193	5,61	4,89–6,43
Plena noite	2.208	287	13,00	11,66–14,47
Pleno dia	3.386	239	7,06	6,24–7,97
Paraíba (PB)	4.244	247	5,82	5,15–6,57
Fora da PB	1.973	356	18,04	16,41–19,80
Rural + simples + noite	708	162	22,88	19,94–26,12

Tabela 8: Testes qui-quadrado de independência contra o desfecho fatal.

Comparação	χ^2	**gl**	p**-valor**	**V de Cramér**
Tipo de pista $\times$ fatal	154,13	2	$3,4 \times 10^{-34}$	0,157
PB $\times$ fora da PB	228,38	1	$1,4 \times 10^{-51}$	0,192
Fase do dia $\times$ fatal	79,29	3	$4,4 \times 10^{-17}$	0,113
Uso do solo $\times$ fatal	145,74	1	$1,5 \times 10^{-33}$	0,153

Tabela 9: Razão de chances (*odds ratio*) de acidente fatal por grupo de exposição.

Grupo de exposição	n **expostos**	**Letal. expostos (%)**	**Letal. demais (%)**	**OR (IC 95%)**
Rural + pista simples	1.840	19,24	5,69	3,95 (3,32–4,69)
Plena noite	2.208	13,00	7,88	1,75 (1,47–2,07)
Fora da PB	1.973	18,04	5,82	3,56 (3,00–4,23)
Rural + simples + noite	708	22,88	8,01	3,41 (2,79–4,17)

Todas as associações são estatisticamente significativas ($p < 0,001$), porém com tamanho de efeito de pequeno a moderado (V de Cramér entre 0,11 e 0,19). Os testes indicam **associação, não causalidade**. A combinação rural + pista simples multiplica as chances de óbito por cerca de 4, o que confirma, com intervalo de confiança, a hipótese levantada na Fase 2.

3.9 Trechos críticos por faixa de quilômetro

Agrupando por UF e faixa de 50 km (mínimo de 30 acidentes), os trechos de maior letalidade são CE km 50–100 (45,7%; 46 acidentes), CE km 0–50 (45,5%; 33), PA km 700–750 (45,5%; 44) e MA km 450–500 (36,4%; 33). Em volume, destaca-se PB km 0–50, com 2.095 acidentes (33,7% da base) e letalidade de apenas 3,1%, o que evidencia o contraste entre o trecho urbano da Grande João Pessoa e os trechos rurais do interior e de outras UF. Esses trechos orientam a construção do mapa de calor.

3.10 Verificação complementar de qualidade

Respondendo às perguntas do Slide 42 da Aula 4:

- **Valores faltantes:** nenhum atributo bruto da base de ocorrências apresenta valores nulos (0%). Os nulos surgem apenas após a integração com a base de pessoas e no tratamento de sentinelas (seção de limpeza).
- **Duplicidade:** 0 identificadores duplicados e 0 linhas totalmente duplicadas.
- **Redundância:** apenas o atributo `br` é constante (BR-230 por construção). O único par com $|r| > 0,8$ é `mortos` $\times$ óbito, já tratado como vazamento.
- **Valores distintos com significado similar:** detectada grafia duplicada em `causa_acidente`, na categoria "Transitar no acostamento", que aparece com diferença de capitalização. A categoria é rara e não é usada como preditor.

4 Formatação dos Dados (Fase 3)

A tarefa *Format data* reestrutura a sintaxe física dos arquivos brutos para assegurar a ingestão padronizada no ambiente analítico sem adulterar o conteúdo dos registros.

4.1 Codificação, delimitadores e tipagem de precisão

Os dados abertos da PRF são disponibilizados com particularidades que inviabilizam rotinas cegas de importação:

- **Codificação:** Os arquivos utilizam `ISO-8859-1` (*latin-1*). A rotina fixa o parâmetro `encoding='latin-1'`, convertendo os textos para UTF-8 nativo em memória;
- **Delimitador e formato numérico:** O separador de campos é o ponto e vírgula (`;`) e o separador decimal é a vírgula (`,`). A especificação `sep=';'` e `decimal=','` garante que coordenadas geográficas (`latitude`, `longitude`) e a quilometragem (`km`) sejam carregadas imediatamente como `float64`, evitando a degradação de campos espaciais em cadeias de texto;
- **Normalização de datas e horas:** Os atributos `data_inversa` e `horario` são convertidos para objetos datetime, derivando os campos padronizados `data`, `hora`, `ano`, `mes` e `dia_semana_norm`;
- **Higienização sintática:** Os identificadores de coluna são convertidos para minúsculas sem espaços periféricos.

4.2 Reprodutibilidade da ingestão

A função `garantir_base()` implementada no notebook gerencia a persistência local em `bases/`. Caso um dos oito CSVs oficiais (`datatran2022.csv` a `datatran2025.csv` e `acidentes2022.csv` a `acidentes2025.csv`) não esteja presente em disco, a rotina realiza o download automático a partir dos espelhos institucionais em nuvem. Para contornar bloqueios em redes com inspeção de tráfego SSL/TLS (proxies corporativos e certificados intermediários), o módulo integra as CAs do sistema operacional ao pacote `certifi`.

5 Seleção e Integração dos Dados

5.1 Integração temporal da série de ocorrências

A consolidação dos quatro exercícios anuais de `datatran` emprega a operação de empilhamento vertical de observações (`pd.concat`). O isolamento da rodovia-alvo é realizado via filtragem explícita: `query("br == 230")`.

A Tabela 10 detalha a evolução anual da base unificada da BR-230.

Tabela 10: Série temporal de ocorrências na BR-230 (base integrada).

Ano de Ocorrência	Acidentes Totais	Acidentes Fatais	Total de Mortos	Proporção Fatal (%)
2022	1.345	135	148	10,04%
2023	1.403	143	160	10,19%
2024	1.724	157	175	9,11%
2025	1.745	168	192	9,63%
Total Consolidado	**6.217**	**603**	**675**	**9,70%**

5.2 Seleção de atributos e prevenção de vazamento

A seleção de preditores respeita o princípio de prevenção de vazamento temporal (*data leakage*). Informações que somente são geradas *após* a ocorrência do sinistro ou como consequência direta de seu desfecho (como `causa_acidente`, `tipo_acidente`, contagens de feridos leves, graves e mortos) foram estritamente excluídas do vetor de entrada dos modelos preditivos.

Tabela 11: Partição dos atributos de acordo com seu papel analítico no pipeline.

Papel Analítico	Atributos Selecionados	Destino no Pipeline
Preditores Contextuais (Entrada)	`km_ajustado`, `latitude`, `longitude`, `hora`, `mes`, `fase_dia`, `condicao_metereologica`, `tipo_pista`, `tracado_principal`, `uso_solo`, `sentido_via`, flags derivadas e variáveis de pessoa agregadas (`envolve_moto`, `envolve_pedestre`, `idade_media`).	Matriz de características (X) para modelagem e espacialização em mapas.
Desfecho (Alvo)	`alvo_fatal` (binário determinístico construído a partir de `classificacao_acidente`).	Vetor alvo (y) supervisionado.
Auditoria e Rastreio	`id`, `uf`, `municipio`, `dia_semana_norm`, `data_inversa`, `causa_acidente`, `tipo_acidente`, `tracado_via` original, `km` bruto, contagens nominais de vítimas.	Arquivo de ocorrências preparadas completas (auditoria); `uf`/`municipio` ficam fora de X por alta cardinalidade.

5.3 Integração com o arquivo por pessoa

Os arquivos de pessoas (`acidentesYYYY.csv`) registram 15.764 linhas na BR-230 no grão **1 linha = 1 pessoa envolvida**. A incorporação desses dados à base principal de ocorrências (**1 linha = 1 acidente**) exigiu agregação relacional prévia via `groupby('id')` para evitar a multiplicação indevida de linhas:

- `envolve_moto`: Indicador booleano (3.584 acidentes envolveram moto);
- `envolve_pedestre`: Indicador booleano (270 acidentes com atropelamento);
- `idade_media`: Média das idades válidas por sinistro (após expurgo de zeros sentinela);
- `prop_masculino`: Proporção de condutores/passageiros do sexo masculino.

A união (*left join*) foi validada como 1:1 estrita: todos os 6.217 acidentes da BR-230 encontraram correspondência exata, mantendo a integridade referencial sem perdas.

6 Limpeza dos Dados e Rastreio da Qualidade

A limpeza dos dados na Fase 3 responde sistematicamente aos seis problemas fundamentais de qualidade diagnosticados na Aula 4 (Slide 42). A Tabela 12 detalha a correspondência entre a dimensão de qualidade e o tratamento aplicado.

Tabela 12: Matriz de rastreio: problemas de qualidade da Aula 4 vs. ações de limpeza da Fase 3.

Dimensão de Qualidade	**Incidência na BR-230**	**Impacto Analítico**	**Tratamento Implementado na Fase 3**
1. Completude (Valores omissos)	876 pessoas com `pesid=0`; 239 acidentes com `idade` sentinela 0 ou > 100 anos.	Média de idade distorcida para baixo na base agregada.	Substituição dos zeros sentinela por `NaN`. Apenas idades de 1 a 100 anos entram em `idade_media`; os 239 nulos são imputados na preparação pela mediana do treino ($33{,}0$ anos).
2. Corretude e Erros Lógicos	1 registro no Tocantins com km 146,0 (acima do teto DNIT de 144,7 km).	Inconsistência cadastral frente ao SNV.	Criação do `km_ajustado` fixado em 144,7 km, preservando a ocorrência e registrando a flag `km_acima_dnit`.
3. Frequência de Erros	109 registros onde a UF do município difere da sigla em `regional`.	Conflito entre circunscrição policial e limite geográfico.	Prevalência estrita das coordenadas WGS84 e do município físico, conforme regra da Fase 2; criação da flag `uf_diverge_regional`.
4. Sinônimos e Múltiplos Rótulos	1.606 registros com múltiplos traçados concatenados por ponto e vírgula (`;`).	Inchaço artificial da cardinalidade categórica.	Extração do `tracado_principal` (primeiro termo) e geração da flag binária `tracado_composto`.
5. Ruídos e Outliers	Trechos com quilometragens acima de 668 km no Pará e Amazonas.	Pontos detectados como anômalos em algoritmos de distância.	Preservação integral após validação geográfica; materialização do fator na flag espacial `fora_pb`.
6. Redundâncias e Duplicações	Chaves duplicadas ou grãos inflados em junções.	Superestimação de ocorrências.	Auditoria de unicidade em `id` (6.217 valores únicos) e agregação rigorosa de pessoas pré-merge.

7 Construção de Atributos e Partição Prospectiva

7.1 Atributos derivados (Engenharia de características)

Com base nas evidências empíricas da Análise Exploratória, foram construídos os seguintes preditores especializados:

- `alvo_fatal` **(Alvo supervisionado):** 1 se `classificacao_acidente` == "Com Vítimas Fatais" e 0 caso contrário.
- `area_urbana` / `area_rural`**:** Variáveis indicadoras derivadas da normalização de `uso_solo`, capturando a diferença crítica de letalidade (14,76% rural vs. 5,61% urbano).
- `fim_de_semana`**:** Indicador booleano ativo para sexta-feira, sábado e domingo, capturando padrões de pico noturno.
- `periodo_noturno`**:** Indicador booleano que consolida "Plena Noite", "Anoitecer" e "Amanhecer" (períodos de visibilidade comprometida).
- `rural_pista_simples`**:** Interação multiplicativa entre traçado simples e meio rural (1.840 ocorrências, foco de gravidade).
- `fora_pb`**:** Indicador geográfico que sinaliza ocorrências fora da Paraíba (onde a letalidade média sobe para 18,04%).

A Figura 4 apresenta os gráficos de controle do pipeline: o volume anual consolidado contra a taxa de letalidade e o perfil de severidade por tipo de pista.

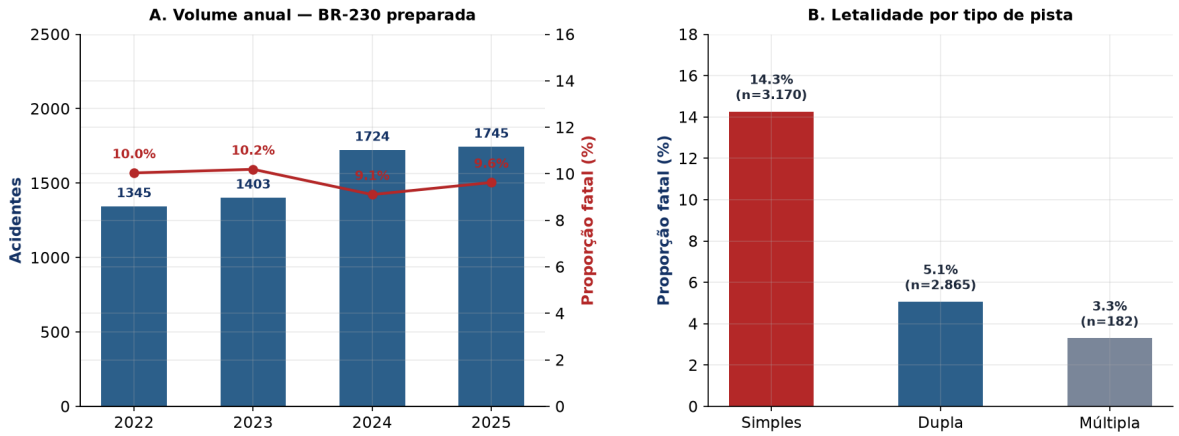


Figura 4: Controle da base preparada: (esquerda) Volume anual de acidentes e proporção fatal estável em torno de 9,7%; (direita) Proporção fatal por configuração de pista na BR-230 (2022–2025).

7.2 Partição prospectiva treino/teste

Diferentemente de divisões puramente aleatórias (como o *k-fold cross validation* descontextualizado), o particionamento temporal preserva a ordem cronológica dos dados e reflete o cenário de aplicação real do modelo em produção [5].

A partição adotada estabelece:

- **Conjunto de Treinamento e Validação:** Triênio histórico de **2022 a 2024**;

- **Conjunto de Teste Prospectivo:** Exercício fechado de **2025**.

A Tabela 13 comprova a estabilidade estatística da proporção de classes em ambos os subconjuntos.

Tabela 13: Distribuição da partição prospectiva temporal para modelagem supervisionada.

Subconjunto de Dados	**Período**	**Acidentes (n)**	**Casos Fatais ($y = 1$)**	**Proporção Fatal (%)**
Treino / Validação	2022 a 2024	4.472	435	9,73%
Teste Prospectivo	2025	1.745	168	9,63%
Total BR-230	**2022 a 2025**	**6.217**	**603**	**9,70%**

A taxa de letalidade permanece virtualmente idêntica entre os conjuntos (9,73% em treino e 9,63% em teste), confirmando a robustez da partição contra desvios de amostragem temporal.

7.3 Desbalanceamento de classes e pesos sugeridos

A classe fatal é minoritária: no treino há 4.037 acidentes não fatais (90,27%) e 435 fatais (9,73%), uma razão de $9,28:1$. Uma acurácia ingênua que preveja sempre "não fatal" atingiria 90,37% no teste, portanto a acurácia não é métrica adequada. Calculamos pesos de classe $n/(2\,n_{\text{classe}})$ somente a partir do treino: $0,554$ para a classe não fatal e $5,140$ para a classe fatal, prontos para uso em `class_weight` na Fase 4. Nenhuma reamostragem foi aplicada nesta fase, preservando a distribuição original do conjunto de teste.

7.4 Codificação categórica e matrizes de aprendizado (X e y)

Para alimentar algoritmos de aprendizado supervisionado (como Redes Neurais Artificiais MLP, Regressão Logística regularizada e modelos de *Boosting*), as variáveis categóricas nominais contextuais foram submetidas ao processo de codificação:

- **One-Hot Encoding (`pd.get_dummies`):** Aplicado sobre `tipo_pista`, `condicao_metereologica`, `uso_solo`, `fase_dia`, `tracado_principal` e `sentido_via`. Foi fixado `drop_first=True` para evitar multicolinearidade exata (armadilha da variável *dummy*);
- **Consistência Dimensional (`reindex`):** O conjunto de teste foi realinhado estritamente pelas colunas geradas no treinamento (`fill_value=0`), garantindo paridade dimensional mesmo na ocorrência de níveis não observados em 2025;
- **Blindagem contra Vazamento (*Data Leakage*):** Valores ausentes no preditor `idade_media` (devidos a indivíduos não qualificados no boletim) foram tratados por imputação pela mediana calculada exclusivamente sobre o conjunto de treino ($33{,}0$ anos). O valor derivado foi subsequentemente imputado tanto em treino quanto em teste, preservando o rigor experimental;
- **Isolamento de Preditores e Desfecho:** Os atributos de identificação, georreferenciamento textual e o desfecho foram desvinculados, resultando nas matrizes analíticas isoladas $X_{\text{treino}} \in \mathbb{R}^{4.472\times 35}$, $y_{\text{treino}} \in \{0,1\}^{4.472}$, $X_{\text{teste}} \in \mathbb{R}^{1.745\times 35}$ e $y_{\text{teste}} \in \{0,1\}^{1.745}$, com taxa de completude de 100% (zero valores nulos).

7.5 Estruturação geoespacial vetorial (WGS84 EPSG:4326)

Visando à construção do mapa de calor de acidentes na Fase de Modelagem por Estimação de Densidade de Kernel (*Kernel Density Estimation* — KDE), as coordenadas geográficas válidas de latitude e longitude foram mapeadas em feições vetoriais de pontos pontuais (`Point`) através da biblioteca GeoPandas, sob o datum geodésico universal WGS84 (EPSG:4326). O arquivo exportado (`br230_espacial.geojson`) contém todas as 6.217 ocorrências com geometria ativa e atributos contextuais associados.

8 Artefatos Gerados e Reprodutibilidade

Todas as transformações, cálculos estatísticos e visualizações são gerados de forma determinística pelo notebook `preparacao_dos_dados/preparacao_dos_dados.ipynb`.

Reprodutibilidade e Execução Interativa:

[Clique aqui para abrir o Notebook no Google Colab]

Os arquivos de dados oficiais gerados encontram-se persistidos no diretório `bases/preparadas/` no formato UTF-8 (delimitado por vírgula) e em formato GeoJSON para as feições espaciais:

Tabela 14: Inventário oficial dos artefatos produzidos pela Fase 3.

Nome do Arquivo	Linhas	Tamanho	Finalidade Analítica
br230_ocorrencias_preparadas.csv	6.217	2,36 MiB	Base completa com todos os atributos contextuais, desfechos de auditoria, coordenadas WGS84 e variáveis de pessoa agregadas.
br230_modelo_completo.csv	6.217	1,15 MiB	Matriz com preditores contextuais selecionados e a variável-alvo alvo_fatal (sem atributos vazadores).
br230_modelo_treino.csv	4.472	830 KiB	Partição de treinamento e calibração (série temporal 2022 a 2024).
br230_modelo_teste.csv	1.745	330 KiB	Partição de avaliação prospectiva independente (série temporal 2025).
X_treino.csv	4.472	680 KiB	Matriz numérica de treino já codificada via One-Hot Encoding (35 preditores).
y_treino.csv	4.472	10 KiB	Vetor de rótulos binários de treino (alvo_fatal).
X_teste.csv	1.745	270 KiB	Matriz numérica de teste prospectivo codificada e alinhada (35 preditores).
y_teste.csv	1.745	4 KiB	Vetor de rótulos binários de teste (alvo_fatal).
br230_espacial.geojson	6.217	8,22 MiB	Camada vetorial espacial WGS84 (EPSG:4326) para estimação de Kernel (KDE).

As figuras de controle e da análise exploratória encontram-se salvas no diretório preparacao_dos_dados/figuras/ em resolução gráfica adequada para publicação:

- exploracao_distribuicoes_outliers.png (Boxplots por UF, Ogiva horária e Heatmap bivariado);
- exploracao_frequencias_pareto.png (Pareto das causas, histograma de km e setores por fase

do dia);

- `exploracao_multivariada.png` (Matriz de correlação e mapa de calor dia $\times$ faixa horária);
- `preparacao_controle_anual_pista.png` (Série anual e perfil por tipo de pista).

9 Encaminhamentos para a Fase 4 (Modelagem)

A conclusão das etapas exploratórias e de preparação fornece os insumos e delimita as restrições metodológicas para a modelagem preditiva supervisionada:

1. **Algoritmos Recomendados:** Treinamento de classificadores probabilísticos capazes de lidar com interações não lineares e variáveis mistas (Gradiente Boosting via LightGBM e XGBoost, Random Forest e Regressão Logística regularizada como *baseline*);
2. **Tratamento do Desbalanceamento:** Como a classe positiva representa 9,70% das instâncias, deve-se adotar ponderação de classes (`scale_pos_weight` ou `class_weight='balanced'`) e calibração fina de limiares de decisão (*threshold tuning*), priorizando a minimização de falsos negativos;
3. **Métricas de Avaliação:** Em consonância com os critérios de sucesso da Fase 1, a performance deve ser avaliada por PR-AUC (Área sob a curva Precisão-Recall), ROC-AUC, F1-Score e Recall na classe fatal, evitando a acurácia global como métrica orientadora;
4. **Dados Faltantes:** A imputação de `idade_media` pela mediana do treino ($33{,}0$ anos) já foi aplicada nas matrizes X; as partições codificadas estão sem nulos. Na Fase 4, permanece opcional testar imputação contextual (ex.: por tipo de veículo) ou o tratamento nativo de nulos em árvores, caso se volte à versão pré-imputação;
5. **Geração do Mapa de Calor:** A camada geográfica de densidade histórica de acidentes será gerada via Estimativa de Densidade por Kernel (KDE) ponderada pela severidade predita do modelo sobre as coordenadas geográficas de `br230_ocorrencias_preparadas.csv`.

Tabela 15: Matriz de cumprimento dos encaminhamentos da Fase 2.

Decisão / Requisito da Fase 2	**Status**	**Solução Implementada na Fase 3**
Base única com recorte BR-230 e partição prospectiva	Cumprida	`concat` dos 4 anos, filtro `query("br==230")`, split temporal 2022–2024 / 2025.
Coordenadas WGS84 limpas e sem nulos	Cumprida	Latitude/longitude numéricas em `float64`, 0 nulos na série da BR-230.
Tratamento de sentinelas de pessoa ($0 \rightarrow$ NaN)	Cumprida	Expurgados zeros em `pesid` e idade; cálculo de idade média válida por acidente.
Redução de traçados compostos	Cumprida	Primeiro traçado isolado em `tracado_principal`; flag de multiplicidade registrada.
Prevalência geográfica e correção cadastral no TO	Cumprida	Prevalência das coordenadas municipais; km 146 ajustado para 144,7 km conforme SNV.
Desbalanceamento severo documentado	Cumprida	9,70% de letalidade total documentada para tratamento algorítmico na Fase 4.

Referências

[1] P. Chapman, J. Clinton, R. Kerber, T. Khabaza, T. Reinartz, C. Shearer e R. Wirth. *CRISP-DM 1.0: Step-by-step data mining guide*. CRISP-DM Consortium, 2000. Disponível em: https://www.datascienceprocess.com/wp-content/uploads/2020/05/crisp-dm-guide.pdf.

[2] Polícia Rodoviária Federal. Dados Abertos da PRF – Acidentes de Tránsito. Portal gov.br, acesso em 13/10/2026. Disponível em: https://www.gov.br/prf/pt-br/acesso-a-informacao/dados-abertos/dados-abertos-da-prf.

[3] Polícia Rodoviária Federal. Anuário Estatístico 2025 da Polícia Rodoviária Federal. Divulgado em Maio de 2026. Disponível em: https://www.gov.br/prf/pt-br/noticias/nacionais/2026/maio/prf-divulga-anuario-estatistico-de-2025-com-aumento-de-infracoes-e-reducao-de-mortes-nas-rodovias-federais.

[4] Departamento Nacional de Infraestrutura de Transportes (DNIT). Restauração e Extensões da Rodovia BR-230. Portal gov.br/dnit, 2026. Disponível em: https://www.gov.br/dnit/pt-br.

[5] J. P. Tozetto, I. Nunes, B. Soares, E. T. Albergaria, D. R. C. Dias, V. F. S. Mota e L. C. D. Rocha. Evaluating Segmentation and Temporal Resolution in Highway Crash Forecasting: The BR-040 Corridor. In *Springer* (capítulo de livro), 2025. DOI: https://doi.org/10.1007/978-3-032-30488-9_36.

[6] D. Santos, J. Saias, P. Quaresma e V. B. Nogueira. Machine Learning Approaches to Traffic Accident Analysis and Hotspot Prediction. *Computers*, 10(12):157, 2021. DOI: https://doi.org/10.3390/computers10120157.

[7] N. Behboudi, S. Moosavi e R. Ramnath. Recent Advances in Traffic Accident Analysis and Prediction: A Comprehensive Review of Machine Learning Techniques. *arXiv preprint* arXiv:2406.13968, 2024. Disponível em: https://arxiv.org/abs/2406.13968.

[8] K. G. Le, P. Liu e L.-T. Lin. Traffic accident hotspot identification by integrating kernel density estimation and spatial autocorrelation analysis: a case study. *International Journal of Crashworthiness*, 27(2):543–553, 2022. DOI: https://doi.org/10.1080/13588265.2020.1826800.

[9] M. Iranmanesh, S. Seyedabrishami e S. Moridpour. Identifying high crash risk segments in rural roads using ensemble decision tree-based models. *Scientific Reports*, 12:21324, 2022. DOI: https://doi.org/10.1038/s41598-022-24476-z.

[10] X. Gao, X. Jiang, J. Haworth, D. Zhuang, S. Wang, H. Chen e S. Law. Uncertainty-aware probabilistic graph neural networks for road-level traffic crash prediction. *Accident Analysis & Prevention*, 208:107801, 2024. DOI: https://doi.org/10.1016/j.aap.2024.107801.

[11] A. A. Khan e J. Hussain. Utilizing GIS and Machine Learning for Traffic Accident Prediction in Urban Environment. *Civil Engineering Journal*, 10(6):1922–1935, 2024. DOI: https://doi.org/10.28991/CEJ-2024-010-06-013.

[12] M. He, G. Meng, X. Wu, X. Han e J. Fan. Road Traffic Accident Prediction Based on Multi-Source Data – A Systematic Review. *Promet – Traffic&Transportation*, 37(2):499–522, 2025. DOI: https://doi.org/10.7307/ptt.v37i2.763.

[13] J. Jeyabharathi, K. J. Lakshmi Prasad, K. Karunakar, K. Sai Charan e R. Sasi Preetham. AI-Driven Traffic Accident Prediction: Integrating Real-Time Weather, Analytics, and Machine Learning for Enhanced Road Safety. In *2026 9th International Conference on Intelligent Computing and Control Systems (ICICCS)*, p. 799–804, 2026. DOI: https://doi.org/10.1109/ICICCS67901.2026.11502769.

[14] H. Affou, D. Teso-Fz-Betoño, U. Fernandez-Gamiz, J. A. Ramos-Hernanz, D. Caballero-Martin e J. M. Lopez-Guede. Advances in Traffic Accident Prediction: A Survey of Novel Approaches. *Urban Science*, 10(7):349, 2026. DOI: `https://doi.org/10.3390/urbansci10070349`.